

Data Mining – Fouille de Données

Projet Data Mining

Réalisé dans le cadre du cours de Data Mining



UCLouvain

Encadrant :

A. AIT EL CADI

Étudiants :

Lenny Andry

Arthur Ottevaere

Date de remise : 15 janvier 2026

Table des matières

Introduction	1
Cahier des charges	2
Titre de l'étude	2
Membres de l'équipe	2
Contexte de l'étude	2
Définition du projet et objectifs	2
Provenance et description des données	3
Problématiques et hypothèses	4
Sample	5
Explore	6
Analyse univariée	6
Variables ordinales	7
Variables nominales	8
Variables continues	9
Variables cibles	11
Analyse multivariée	12
Matrice de corrélation de Spearman	12
Matrice de corrélation de Pearson	13
Matrices de contigence	14
Interprétation globale	17
Modify	19
Gestion des valeurs manquantes	19
Détection des outliers	19
Discrétisation des variables continues	19
Sélection des variables pertinentes	21
Model & Assess	22
Modèles supervisés	22
Métriques de performance	23
Approche initiale : classification multi-classes	24
JobSatisfaction comme variable cible	24
Stress comme variable cible	25
Nouvelle approche : classification binaire	26
JobSatisfaction comme variable cible	26
Stress comme variable cible	27
Amélioration des modèles	27

Visualisation et validation des variables discriminantes	28
Modèles non supervisés	29
Clustering hiérarchique	29
Analyse du clustering hiérarchique	30
K-means	31
Analyse du K-means	32
Choix du modèle final	32
Caractérisation des clusters	33
Synthèse globale	35
Synthèse de la fouille des données	36
Sample	36
Explore	36
Modify	37
Model & Assess	37
Discussion des résultats : problématiques et hypothèses	40
Problématique 1 : Stress au travail	40
Problématique 2 : Satisfaction professionnelle	40
Problématique 3 : Caractérisation des groupes d'employés	41
Conclusion relative aux problématiques et hypothèses	42
Conclusion	43
Conclusion sur l'exercice	45

Introduction

L'objectif de ce rapport est de mettre en œuvre une démarche complète de data mining afin d'analyser les facteurs exerçant une influence sur les deux dimensions essentielles du bien-être au travail que sont le stress et la satisfaction. L'environnement professionnel étant en perpétuelle évolution, il devient indispensable pour les organisations de pouvoir appréhender les déterminants du bien-être et de la satisfaction, notamment afin de pouvoir préserver et fidéliser leurs talents.

Le jeu de données mobilisé, issu d'une enquête RH fictive, forme une base solide afin d'analyser l'influence de diverses caractéristiques (personnelles, professionnelles et organisationnelles) sur l'expérience des employés. Dans le cadre de ce travail, nous suivrons de manière rigoureuse la méthodologie *SEMMA* (Sample, Explore, Modify, Model, Assess). Cette approche, largement répandue dans de nombreux domaines, permet un encadrement de notre analyse depuis la collecte des données jusqu'à la construction et l'évaluation des modèles supervisés et non supervisés construits.

Concernant l'organisation de ce rapport, il s'articule en plusieurs étapes : dans un premier temps, il présente le cahier des charges définissant le contexte, les objectifs et la provenance des données du projet. Il est également question dans cette partie de lister les problématiques soulevées ainsi que de formuler des hypothèses de travail. L'étape suivante consiste à présenter en détail la fouille de données menée, incluant l'exploration, le nettoyage et la transformation du dataset. Vient ensuite la construction de divers modèles de classification, régression et clustering, qui font l'objet d'une évaluation et d'une comparaison afin d'optimiser la prédiction du stress et de la satisfaction. Enfin, par le biais de l'analyse des résultats obtenus, des réponses concrètes sont apportées aux problématiques et aux hypothèses formulées. L'objectif final est bien entendu de pouvoir exprimer des recommandations à destination de tout département RH soucieux d'améliorer la satisfaction de ses collaborateurs au travail.

Cahier des charges

Titre de l'étude

Comprendre le bien-être au travail : analyse des déterminants et de leurs impacts, prédiction et clustering RH.

Membres de l'équipe

Lenny Andry – `lenny.andry@student.uclouvain.be`

Arthur Ottevaere – `arthur.ottevaere@student.uclouvain.be`

Contexte de l'étude

La transformation des environnements professionnels, l'intensification de la concurrence économique et la transition digitale ont grandement impacté la notion de bien-être au travail. De nos jours, les organisations sont confrontées à des défis majeurs : surcharge de travail, augmentation du turnover, besoins de flexibilité, attentes concernant l'équilibre entre vie privée et vie professionnelle. Afin de pouvoir faire face à ces enjeux, la fonction RH a recours, de manière grandissante, à des méthodes quantitatives cherchant à mieux appréhender les risques psychosociaux tout en favorisant la satisfaction et le bien-être de leurs collaborateurs. L'application de la science des données permet de mettre en avant différents facteurs affectant le stress et la satisfaction, des critères essentiels à la rétention des talents. Le projet proposé vise à prendre part à cette logique : il a pour objectif d'exploiter un jeu de données synthétiques afin de révéler les variables qui expliquent la satisfaction au travail, mais également de développer des modèles de machine learning solides.

Définition du projet et objectifs

Ce travail consiste en grande partie en l'application d'une démarche de data mining au domaine des ressources humaines. Cette démarche s'appuie sur le fil rouge méthodologique *SEMMA* (Sample, Explore, Modify, Model, Assess) s'étendant de la collecte des données à la modélisation et l'évaluation des résultats obtenus. L'objectif de cette étude sera triple :

- Analyser l'impact des variables affectant le stress et la satisfaction des forces de travail à partir d'informations personnelles, professionnelles et organisationnelles.
- Développer et comparer des modèles prédictifs afin de déterminer avec la plus grande précision les niveaux de stress et de satisfaction, et ainsi fournir des pistes de leviers actionnables aux équipes RH.
- Développer et comparer des méthodes de clustering afin de créer des groupes homogènes d'individus, sur la base de leurs caractéristiques personnelles, professionnelles et organisationnelles, dans le but d'aider le personnel RH à prendre des décisions managériales éclairées.

Provenance et description des données

Le jeu de données utilisé (« Employee Survey ») provient du site communautaire *Kaggle*, qui est l'une des plus grandes plateformes dédiées à la science des données et à l'apprentissage automatique. Chacune des 3025 instances d'observation correspond à l'ensemble des caractéristiques décrivant un employé particulier (grâce à l'ID unique lui étant attribué). Les variables englobent :

TABLE 1 – Catégories de variables, noms et descriptions

Catégorie	Variable	Description
Attributs personnels		
–	EmpID	Identifiant unique attribué à chaque employé.
–	Gender	Genre de l'employé (ex. : Homme, Femme, Autre).
–	Age	Âge de l'employé.
–	MaritalStatus	Situation matrimoniale (Célibataire, Marié, Divorcé, Veuf).
–	PhysicalActivityHours	Nombre d'heures d'activité physique par semaine.
–	SleepHours	Nombre d'heures de sommeil par nuit.
–	EduLevel	Niveau d'éducation le plus élevé atteint (ex. : Bachelier, Master, Doctorat).
Attributs professionnels		
–	JobLevel	Niveau hiérarchique (Intern, Junior, Mid, Senior, Lead).
–	Experience	Nombre d'années d'expérience professionnelle.
–	Dept	Département d'affectation (IT, RH, Finance, Marketing, etc.).
–	EmpType	Type de contrat (Temps plein, Temps partiel, Contrat).
–	TeamSize	Taille de l'équipe dont fait partie l'employé.
–	NumReports	Nombre de personnes supervisées (pour Senior/Lead).
–	TrainingHoursPerYear	Nombre d'heures de formation reçues par an.
–	NumCompanies	Nombre d'entreprises précédentes dans lesquelles l'employé a travaillé.
–	haveOT	Indique si l'employé effectue des heures supplémentaires (Vrai/Faux).
Attributs organisationnels et environnementaux		
–	WLB	Évaluation de l'équilibre vie privée / vie professionnelle (1 à 5).
–	WorkEnv	Évaluation de l'environnement de travail (1 à 5).
–	Workload	Évaluation de la charge de travail (1 à 5).
–	CommuteMode	Mode de transport utilisé pour le trajet (Voiture, Bus, Vélo, Marche...).
–	CommuteDistance	Distance du trajet domicile-travail (en kilomètres).
Variables de sortie		
–	Stress	Niveau de stress ressenti (1 à 5).
–	JobSatisfaction	Niveau de satisfaction professionnelle (1 à 5).

L'ensemble des données à disposition sera divisé en deux ensembles :

- **Apprentissage (80%)** pour la construction des modèles.
- **Validation (20%)** pour l'évaluation des modèles.

Problématiques et hypothèses

Notre étude est guidée par trois problématiques fondamentales :

1. **Stress au travail** : Quels sont les facteurs principaux, parmi ceux identifiés, qui expliquent le stress ressenti par un employé, et permettent de prédire son niveau de stress ?
2. **Satisfaction professionnelle** : Quels sont les déterminants expliquant la satisfaction professionnelle des employés, et permettant de prédire leur niveau de satisfaction ?
3. **Caractérisation des groupes d'employés** : Comment peut-on regrouper les employés en clusters homogènes afin d'identifier des profils types et d'aider le personnel RH dans ses décisions managériales ?

Relativement à ces problématiques, trois hypothèses sont formulées :

1. Une charge de travail élevée, un manque de temps de sommeil, un faible niveau d'activité physique et un piètre équilibre entre vie privée et vie professionnelle participent à la génération du stress, et ces facteurs permettent de prédire le stress ressenti.
2. Un environnement de travail de qualité, un niveau de formation élevé et l'occupation d'un poste à responsabilité favorisent la satisfaction professionnelle, et ces facteurs permettent de prédire le niveau de satisfaction.
3. Les facteurs démographiques ont une influence secondaire mais significative sur la perception du stress et la satisfaction, et peuvent aider à définir les groupes d'employés lors de l'analyse par clustering.

TABLE 2 – Variables et impact attendu

Variable	Impact sur Stress / Satisfaction
Workload	↑ Stress
PhysicalActivityHours	↓ Stress
SleepHours	↓ Stress
WLB	↓ Stress
WorkEnv	↑ Satisfaction
TrainingHoursPerYear	↑ Satisfaction
JobLevel	↑ Satisfaction

Sample

La première étape de la méthodologie *SEMMA*, l'échantillonnage (Sample), consiste à collecter les données et à vérifier leur adéquation avec l'étude. Cette phase est cruciale pour garantir la fiabilité des modèles qui seront construits par la suite.

Le jeu de données retenu ("Employee Survey") comporte 3 025 observations et 23 variables. Une première analyse de la qualité des données confirme l'absence de valeurs manquantes (0 missing values), ce qui témoigne de la propreté du dataset et nous dispense de procédures d'imputation lourdes. Il s'agira ensuite de s'assurer de la bonne qualité de ces données, en procédant à l'analyse descriptive de nos variables lors de la phase "Explore".

Enfin, conformément à la méthode *SEMMA*, nous avons procédé au partitionnement des données (Data Splitting) pour préparer la phase de modélisation :

- **Ensemble d'Apprentissage (Train Set) : 80%** des données (2 420 observations), utilisé pour entraîner nos algorithmes.
- **Ensemble de Test (Test Set) : 20%** des données (605 observations), conservé strictement pour l'évaluation finale (Assess).

Explore

Analyse univariée

Comme évoqué plus haut, l'analyse descriptive de nos variables est essentielle afin d'en assurer la conformité et la qualité. Vous trouverez donc dans le tableau ci-dessous nos variables accompagnées de quelques mesures de tendances centrales. Ces variables sont divisées en catégorie, où "Attributs personnels", "Attributs professionnels" et "Attributs organisationnels et environnementaux" représentent les variables indépendantes. Tandis que la catégorie "Indicateurs", ne contient que les variables dépendantes.

TABLE 3 – Statistiques Descriptives des Données (N = 3025)

Catégorie	Variable	Statistiques Clés
<i>Attributs personnels</i>	Age	Moyenne : 35.7 ans ($\sigma = 10.2$), Médiane : 34 ans
	Gender	Hommes (50.5%), Femmes (41.0%), Autre (8.5%)
	EduLevel	Bachelor (76.0%), Master (12.6%), Secondaire (8.1%)
	MaritalStatus	Célibataires (47.5%), Mariés (46.2%), Divorcés (6.2%)
	SleepHours	Moyenne : 7.0 h (Min : 4.0 h)
	PhysicalActivityHours	Moyenne : 2.0 h (Médiane : 2.0 h)
<i>Attributs professionnels</i>	Dept	IT (25.6%), Finance (21.1%), Opérations (15.0%)
	JobLevel	Senior (35.3%), Intermédiaire (25.3%), Junior (19.9%)
	Experience	Moyenne : 9.1 ans (Max : 29 ans)
	EmpType	Temps Plein (68.7%), Partiel (21.2%), Autre (10.2%)
	haveOT	30.9% effectuent des heures supplémentaires
	TeamSize	Moyenne : 16.52 personnes (Min : 5 & Max : 30)
	TrainingHoursPerYear	Moyenne : 37.3 h/an
	NumReports	Moyenne : 2.38
<i>Attributs organisationnels & environnementaux</i>	NumCompanies	Moyenne : 4.25 (Max : 12)
	CommuteDistance	Moyenne : 13.5 km
	CommuteMode	Voiture (35.9%), Transports (29.6%), Vélo (14.4%)
	WLB (1-5)	Moyenne : 3.06 ($\sigma = 1.45$)
	WorkLoad (1-5)	Moyenne : 2.97 ($\sigma = 1.40$)
	WorkEnv (1-5)	Moyenne : 3.03
<i>Indicateurs</i>	JobSatisfaction (1-5)	Moyenne : 3.39 ($\sigma = 1.26$)
	Stress (1-5)	Moyenne : 1.74 ($\sigma = 1.06$)

L'analyse descriptive (voir Table 3) révèle une population relativement jeune (35 ans) et majoritairement masculine, issue principalement des départements IT et Finance. Un point notable est le niveau de stress déclaré qui semble bas en moyenne (1.74), contrastant avec une satisfaction professionnelle modérée (3.39) et un équilibre vie privée / vie professionnelle jugé moyen (3.06). Cela suggère que le stress n'est pas le seul frein au bien-être : d'autres facteurs (ennui, manque de challenge, environnement) pourraient s'avérer impactants.

Variables ordinales

Dans un premier temps, la partie qui suit porte sur l'analyse univariée des variables ordinales, ce qui permet d'examiner leur distribution et d'en dégager les principales caractéristiques.




FIGURE 1 – Distributions variables ordinales

L'histogramme de la variable WLB indique une distribution asymétrique à droite, expliquée par une concentration plus élevée sur les valeurs 4 et 5. Le mode de cette variable étant la valeur 5, cela indique qu'un grand nombre d'employés juge avoir un excellent équilibre entre leur vie privée et professionnelle. Bien que les scores de 2 et 3 soient légèrement plus faibles, ils ne restent pas pour autant moins représentés par rapport aux autres valeurs. Aucun effet plancher ou plafond n'est observé malgré la préférence pour les valeurs élevées, comme discuté précédemment. Ces constatations traduisent soit l'existence d'une potentielle bonne politique interne de gestion de l'équilibre entre vie privée et professionnelle, soit une perception positive de cette dimension par les collaborateurs.

La distribution de la variable WorkEnv semble relativement équilibrée. Cependant, deux groupes dominants ressortent : celui des individus fortement satisfaits par leur environnement de travail (score 5) et celui des individus plus neutres (score 3). Le score de 4 apparaît comme inférieur aux autres valeurs, marquant une rupture dans la tendance croissante de la distribution. En moyenne, dû à une occurrence équilibrée de chaque valeur, les individus sont modérément satisfaits de leur environnement de travail.

Concernant la variable Workload, l'histogramme présente une distribution quasiment uniforme entre l'ensemble des scores. En effet, un plateau se forme pour les scores allant de 1 à 4, suivi d'une baisse au niveau du score 5. La plupart des employés ont une charge de travail modérée (moyenne de 2.97), mais la diversité reste importante.

Variables nominales

Dans un second temps, la partie qui suit porte sur l'analyse univariée des variables catégorielles nominales, ce qui permet d'examiner la répartition des modalités et d'identifier les principales tendances.




FIGURE 2 – Distributions variables nominales

Dept : Une forte hétérogénéité apparaît au sein de la distribution. En effet, certains départements sont fortement représentés tels que la Finance, l'IT ou encore les Opérations, là où d'autres le sont beaucoup moins, comme le Customer Service et le HR. La structure organisationnelle de l'entreprise est donc assez déséquilibrée. Cette hétérogénéité notable risque potentiellement d'impacter les analyses multivariées qui suivront.

JobLevel : La distribution affiche un effectif majoritairement expérimenté dû au niveau Senior dominant. Cette figure est typique d'une organisation mature, peu orientée vers des profils débutants. Cette idée est appuyée par le fait que les catégories Junior et Intern (en grande partie), sont largement sous représentées. Malgré une structure pyramidale inversée, le nombre d'individu appartenant à la catégorie Lead reste faible, ce qui est le cas pour la plupart des organisations mondiales.

MaritalStatus : Forte prépondérance des status Married et Single observée par rapport aux individus appartenant à la classe Divorced et Widowed.

EmpType : Les employés en « Full-Time » sont ultra dominants. Par conséquent, l'intérêt statistique de cette variable reste limité.

CommuteMode : Les modes de transport que sont la voiture et les transports publics dominent largement. Les modes de mobilité doux tels que le vélo et la marche sont moins fréquemment utilisés. Cette tendance dans la distribution peut potentiellement être due à une distance domicile-travail importante, qui justifierait alors le recours à des moyens de déplacement plus traditionnels.

EduLevel : La grande partie des effectifs présente un niveau d'éducation se limitant au bachelier. Parmi les catégories sous représentées (High School, Master, PhD), celle des individus possédant un Master domine. Le nombre restreint de titulaires d'un PhD indique que l'organisation ne privilégie pas un haut degré d'expertise scientifique.

haveOT : Une grande majorité (60%) des employés (principalement ceux issus du département Finance) déclarent ne pas réaliser d'heures supplémentaires. Cependant, le sous-groupe TRUE (celui réalisant des heures supplémentaires) reste significatif, principalement influencé par un noyau spécifique d'employés (ici ceux issus du département IT).

Variables continues

Dans un troisième temps, la partie qui suit porte sur l'analyse univariée des variables continues, réalisée à l'aide de boxplots afin de mettre en évidence leur dispersion, leur tendance centrale ainsi que la présence éventuelle de valeurs atypiques.




FIGURE 3 – Boxplots variables continues

Commute distance : La distance domicile-travail des employés varie fortement, entre 1 et 29km. Cela traduit la coexistence entre des profils locaux et des collaborateurs plus éloignés de leur lieu de travail. La médiane se situe autour de 13km, avec la moitié des observations comprises entre 6 et 21 km. La dispersion est élevée, et quelques valeurs extrêmes apparaissent, sans être aberrantes. Cette variable est à conserver car elles constituent potentiellement un facteur de stress important.

Experience : A nouveau, l'expérience est une variable présentant une forte dispersion, allant de 0 à 29 ans. La médiane se situe autour de 8 ans, reflétant une prédominance des profils seniors comme énoncé précédemment dans l'analyse. La box illustre tout de même que la moitié des effectifs présente une expérience comprise entre 3 et 14 ans. Cela signifie que, bien que les employés de type Senior soient majoritaires, les employés de type Mid sont, eux aussi, fortement présents.

Age : La variable correspondant à l'âge s'étale de 22 à 60 ans, avec une médiane autour de 34 ans. La box nous informe que la moitié des individus observés ont entre 27 et 43 ans. La population active est donc jeune voir d'un âge moyen. L'ensemble de ces constatations semblent cohérentes avec celles émises pour la variable liée à l'expérience.

TrainingHoursPerYear : La variabilité de la variable relative au nombre d'heures de formation par an s'étend de 10 à 64.5 heures. La médiane, quant à elle, se situe autour de 40 heures de formation par an. L'investissement en formation apparaît comme étant important mais pas uniforme. En effet, bien qu'une politique de formation soit mise en place, elle ne semble pas être distribuée de manière égale selon les différents postes. Cela peut s'expliquer par la sur-représentativité de certains départements (Finance et IT).

SleepHours : Le nombre d'heures de sommeil par nuit varie entre 4 et 10 heures avec une médiane à 7 heures. Quelques outliers sont tout de même observés, proches de 4 et 10 heures de sommeil par nuit. Cet indicateur constitue un marqueur important de santé pouvant avoir un impact significatif sur le stress d'un individu.

PhysicalActivityHours : Le nombre d'heures allouées à la pratique d'activités physiques sur la semaine s'étend de 0 à 5 heures avec une médiane étant située autour de 2 heures. La moitié des valeurs observées sont situées entre 1.3 et 2.7 heures. Le volume d'activité physique réalisé est relativement faible illustré par de nombreuses valeurs proches de 0. Quelques employés pratiquent davantage (4-5 heures) mais restent tout de même minoritaires. Ces constatations peuvent induire des niveaux de stress plus importants.

Variables cibles

Enfin, la partie qui suit porte sur l'analyse des variables cibles, à savoir le stress et la satisfaction. L'objectif est d'examiner leur distribution et leurs caractéristiques principales.




FIGURE 4 – Distributions variables cibles

La distribution de la satisfaction révèle une situation contrastée mais positive. La majorité des employés attribue une note élevée en ce qui concerne la satisfaction au travail, en particulier un score de 4 et 5. Le score dominant (mode) est 4, soulignant une satisfaction au travail importante. Cependant, un second groupe non négligeable est quant à lui situé sur des niveaux de satisfaction bien plus faibles, notamment en 1 et 2. Ce contraste peut s'expliquer par de potentielles réalités professionnelles différentes en fonction des départements, des heures de formation par an ou encore de niveau hiérarchique.

La situation est nettement différente lorsqu'il s'agit du stress. La distribution est clairement asymétrique avec des niveaux de stress principalement faibles. La modalité 1 est de loin la plus observée, suivie des valeurs 2 et 3. Les modalités 4 et 5 sont, quant à elles, les moins fréquentes. Ainsi, le stress apparaît globalement faible au sein de l'organisation, avec une majorité d'employés concentrée sur les niveaux les plus bas.

Analyse multivariée

Après avoir analysé individuellement l'ensemble des variables du dataset à travers l'analyse univariée, il convient désormais de se pencher sur les relations existantes entre elles. L'analyse multivariée a pour but d'étudier la manière dont les variables interagissent afin de détecter des éventuels patterns et d'identifier les facteurs pouvant influencer les variables cibles. Afin de détecter de potentiels liens monotones ou linéaires entre les variables ordinales, nominales et continues, deux matrices de corrélation sont mobilisées : la matrice de Pearson, centrée sur les associations linéaires, et la matrice de Spearman plus adaptée aux distributions non linéaires.

Matrice de corrélation de Spearman




FIGURE 5 – Matrice de corrélation de Spearman

La matrice de corrélation de Spearman met en lumière de multiples relations monotones marquées entre les variables socio-professionnelles décrivant l'évolution de carrière. L'analyse univariée renseignait déjà sur des relations fortes entre l'âge, l'expérience professionnelle et le nombre d'entreprises au sein desquelles les employés ont déjà travaillé. L'âge présente un fort degré de corrélation avec la variable NumCompanies (0.995), ce qui semble tout à fait logique avec la réalité observée. En effet, un employé plus âgé aura tendance à avoir changé plus souvent d'employeurs au cours de sa carrière professionnelle. Cette observation est soutenue par une corrélation élevée entre les variables Experience et NumCompanies (0.73). Avec l'âge, une personne a naturellement plus d'expérience et a souvent travaillé dans un plus grand nombre d'organisations.

De plus, un autre coefficient affichant une valeur importante concerne la formation. Les employés, plus âgés ou expérimentés réalisent davantage d'heures de formation annuelle ($\rho = 0.84$ entre TrainingHoursPerYear et Age, $\rho = 0.78$ entre TrainingHoursPerYear et Experience). Cela peut no-

tamment s'expliquer par l'organisation interne, où les collaborateurs ayant plus de responsabilités se voient offrir plus de formations.

Une autre liaison pouvant être soulignée est celle qui existe entre TeamSize et NumReports ($\rho = 0.65$). A nouveau, cette relation semble assez logique au sein d'une structure hiérarchique classique. Les employés, et plus spécifiquement les niveaux Senior et Lead, gérant des équipes de grandes tailles auront logiquement un plus grand nombre de subordonnés auxquels ils seront rattachés. Cela atteste de la cohérence de la base de données avec la réalité.

Au-delà de ces observations structurelles, la satisfaction professionnelle affiche des liens modérés mais conformes à nos hypothèses. La satisfaction est impactée positivement lorsque l'environnement de travail est jugé positif ($\rho = 0.25$) ou lorsqu'il y a un bon équilibre entre vie privée et vie professionnelle ($\rho = 0.25$), et inversement en cas de charge de travail élevée ($\rho = -0.25$).

Au contraire, les variables relatives aux habitudes personnelles (CommuteDistance, SleepHours, Workload, PhysicalActivityHours) affichent des coefficients de corrélation faibles entre elles et avec les autres variables. Dans la continuité de l'analyse univariée, l'absence de corrélation suggère que ces dimensions dépendent surtout des individus, plutôt que de déterminants organisationnels comme le département, la position hiérarchique ou l'ancienneté. Le stress affiche lui aussi une faible corrélation avec les autres variables. Cela s'explique par sa distribution asymétrique concentrée sur des niveaux faibles. Pour ce qui est de la satisfaction, elle apparaît comme étant seulement faiblement corrélée à certaines autres variables, ce qui laisse penser qu'elle dépend également de facteurs non présents dans le jeu de données.

Matrice de corrélation de Pearson




FIGURE 6 – Matrice de corrélation de Pearson

La matrice de corrélation de Pearson confirme les tendances observées avec Spearman. En effet, les relations linéaires entre l'âge, l'expérience et le nombre d'heures de formation par an restent importantes même si elles sont bien moins extrêmes que celles observées dans Spearman. Cela suggère que les profils plus expérimentés suivent davantage de formations, mais le temps qui y est consacré n'augmente pas systématiquement avec l'avancement de carrière. A nouveau, comme souligné dans la matrice de Spearman, les variables relatives aux habitudes personnelles restent largement indépendantes des autres variables. Cela suggère non seulement une absence de tendance monotone mais également une absence de structure linéaire. Ces éléments semblent donc totalement détachés de la dynamique de carrière.

Matrices de contingence

Dans la continuité de l'analyse multivariée, l'étude des relations entre variables discrètes et catégorielles repose désormais sur l'examen de matrices de contingence. Seules les plus pertinentes au regard des hypothèses formulées initialement sont présentées.

Stress	WorkLoad					Total
	1	2	3	4	5	
1	20.8	20.5	19.1	21.1	18.5	100.0
2	18.7	21.1	24.1	18.1	17.9	100.0
3	19.7	20.4	18.8	22.1	19.0	100.0
4	22.9	19.0	21.2	17.3	19.6	100.0
5	15.8	18.4	23.7	22.4	19.7	100.0

TABLE 4 – Matrice de contingence entre Stress et WorkLoad (en %)

Stress - WorkLoad : L'analyse de la relation entre le stress et la charge de travail (WorkLoad) révèle un résultat surprenant et contre-intuitif, mais qui pourrait être propre au jeu de données. En effet, une corrélation prononcée devrait être représentée par une diagonale marquée dans la matrice. Ici, la répartition des scores de la charge de travail reste relativement stable. Cela signifie que WorkLoad ne permet pas de prédire efficacement le niveau de stress exprimé par les individus.

Stress	WLB					Total
	1	2	3	4	5	
1	20.6	17.8	18.4	20.6	22.6	100.0
2	20.6	18.1	19.6	21.1	20.6	100.0
3	20.4	20.4	16.4	20.4	22.3	100.0
4	19.6	19.0	18.4	24.0	19.0	100.0
5	18.4	18.4	10.5	22.4	30.3	100.0

TABLE 5 – Matrice de contingence entre Stress et WLB (en %)

Stress - WLB : L'analyse de la matrice de contingence confirme l'anomalie relative au stress, détectée par le biais de la matrice de Spearman et la précédente analyse. Il n'existe aucune dépendance statistique entre la perception de l'équilibre vie privée/professionnelle et le niveau

de stress déclaré. La répartition quasi-uniforme des pourcentages suggère que, pour cette population, le stress est totalement décorrélié de la charge de travail ou de la conciliation vie privée/professionnelle. Ce résultat est donc dans la logique de ceux obtenus précédemment.

Stress	haveOT		Total
	FALSE	TRUE	
1	69.5	30.5	100.0
2	68.2	31.8	100.0
3	69.0	31.0	100.0
4	65.9	34.1	100.0
5	71.1	28.9	100.0

TABLE 6 – Matrice de contingence entre Stress et haveOT (en %)

Stress - haveOT : L'analyse révèle tout d'abord qu'indépendamment du niveau de stress, plus de six employés sur dix ne prestent pas d'heures supplémentaires. Dans un second temps, la matrice met en évidence la corrélation quasi nulle du stress par rapport aux autres variables (ici haveOT), ce qui suggère que les relations complexes liées au stress n'ont pas été prises en compte dans le jeu de données ou que la source du stress est purement interne à l'organisation (conflits, management) et non liée au temps de travail. Il est également important de noter le paradoxe qui apparaît entre le niveau de stress 4 et 5. En effet, un pic d'heures supplémentaires apparaît au niveau 4, là où le niveau 5 correspond à la proportion la plus faible d'employés concernés.

JobSatisfaction	WorkEnv					Total
	1	2	3	4	5	
1	36.9	26.6	20.4	9.6	6.5	100.0
2	12.6	15.9	24.5	23.1	23.8	100.0
3	28.6	24.6	19.6	14.1	13.1	100.0
4	13.1	19.2	21.8	20.7	25.3	100.0
5	12.8	13.6	18.4	24.4	30.8	100.0

TABLE 7 – Matrice de contingence entre JobSatisfaction et WorkEnv (en %)

JobSatisfaction - WorkEnv : L'analyse de ce tableau met en lumière une dualité intéressante. D'une part, une corrélation forte aux extrêmes apparaît. En effet, la relation est linéaire et logique pour les niveaux de satisfaction extrêmes. Les employés très insatisfaits (Niveau 1) jugent massivement leur environnement de travail sévèrement (63.5% de notes 1 et 2), tandis que les très satisfaits (Niveau 5) l'évaluent plus positivement (55.2% de notes 4 et 5). D'autre part, une rupture de linéarité se fait nettement ressentir pour les employés "moyennement satisfaits". Au lieu de se concentrer sur une note d'environnement moyenne (3), une majorité d'entre eux (53.2%) attribuent une mauvaise note (1 ou 2) à leur environnement. Ce constat suggère que, pour le niveau intermédiaire, l'environnement de travail n'est pas le facteur déterminant.

JobSatisfaction	JobLevel					Total
	Intern	Junior	Lead	Mid	Senior	
1	6.7	20.4	16.5	23.3	33.1	100.0
2	7.2	19.5	10.1	24.9	38.3	100.0
3	6.2	21.2	11.3	26.3	35.0	100.0
4	7.2	18.8	13.0	26.2	34.8	100.0
5	5.6	20.9	12.2	24.0	37.2	100.0

TABLE 8 – Matrice de contingence entre JobSatisfaction et JobLevel (en %)

JobSatisfaction - JobLevel : Comme souligné dans nos analyses précédentes, la matrice de contingence met en évidence que les postes à forte responsabilité sont davantage représentés dans le jeu de données utilisé. Toutefois, elle indique également que le niveau hiérarchique n'est pas un déterminant de la satisfaction. En effet, celle-ci semble être répartie de manière homogène à travers l'ensemble des échelons : un stagiaire a autant de chances d'être épanoui (ou malheureux) qu'un senior.

JobSatisfaction	EduLevel				Total
	Bachelor	High School	Master	PhD	
1	85.1	6.7	3.4	4.8	100.0
2	87.0	7.9	0.0	5.1	100.0
3	60.2	9.2	27.0	3.5	100.0
4	78.5	8.2	9.7	3.7	100.0
5	74.2	7.9	17.8	0.0	100.0

TABLE 9 – Matrice de contingence entre JobSatisfaction et EduLevel (en %)

JobSatisfaction - EduLevel : La matrice de contingence montre une corrélation très peu présente entre la satisfaction générale au bureau et le niveau d'éducation des employés. Néanmoins, plusieurs phénomènes apparaissent. D'une part, la sur-représentation des titulaires d'un Bachelor reflète davantage la structure démographique de l'échantillon qu'un lien avec leur satisfaction. D'autre part, la distribution des titulaires d'un Master selon le niveau de stress apparaît erratique : fortement présents au niveau 3, ils connaissent une chute marquée au niveau 4. Aucune conclusion relative à l'épanouissement ne peut donc être tirée. Finalement, la présence de valeurs nulles dans la matrice traduit un effectif insuffisant pour certaines sous-catégories, rendant toute interprétation définitive statistiquement fragile.

JobSatisfaction	Dept								Total
	Cust.	Fin.	HR	IT	Legal	Marketing	Op.	Sales	
1	5.3	18.9	5.0	32.1	8.4	11.5	13.2	5.5	100.0
2	5.8	22.4	3.2	22.7	9.0	10.5	15.9	10.5	100.0
3	4.2	21.4	4.8	27.0	8.1	9.9	13.1	11.5	100.0
4	5.1	20.1	5.1	23.9	10.4	10.5	15.9	9.0	100.0
5	4.1	24.0	4.3	24.4	7.0	10.1	16.3	9.9	100.0

TABLE 10 – Matrice de contingence entre JobSatisfaction et Dept (en %)

JobSatisfaction - Dept : Cette analyse renseigne surtout sur la structure du jeu de données, marquée par des services Finance et IT sur-représentés. Il est important de noter que cette disproportion n'en dit que très peu quant à leur niveau de satisfaction au travail. Néanmoins le département IT révèle une particularité : malgré sa forte présence au sein du dataset, il présente une proportion élevée d'employés peu satisfaits en son sein. Cette observation constitue une potentielle problématique qui mérite une investigation approfondie.

Stress	Dept								Total
	Cust.	Fin.	HR	IT	Legal	Marketing	Op.	Sales	
1	5.1	19.8	4.6	26.4	8.8	10.6	15.8	9.0	100.0
2	3.9	22.4	5.2	26.2	9.0	9.5	12.7	11.0	100.0
3	5.9	22.3	4.2	23.2	9.2	10.8	15.0	9.4	100.0
4	2.8	24.6	6.1	23.5	10.1	9.5	17.3	6.1	100.0
5	5.3	25.0	3.9	21.1	10.5	14.5	9.2	10.5	100.0

TABLE 11 – Matrice de contingence entre Stress et Dept (en %)

Stress - Dept : Cette dernière matrice de contingence apporte des éléments significatifs concernant les départements et leur niveau de stress, en particulier lorsqu'elle est comparée à celle mettant en relation JobSatisfaction et Dept (voir Table 10). En effet, malgré un service IT peu satisfait, ses employés ne semblent pas nécessairement stressés. Leur mal-être paraît davantage lié à un manque de sens ou à une insatisfaction interne. Le département Finance, quant à lui, ne présentait pas de signes particuliers d'insatisfaction, mais révèle ici une tendance à la hausse concernant le stress. Cela pourrait possiblement être dû aux exigences en matière de performance financière et aux tensions qu'elle engendre au sein des équipes. Les départements Marketing et Legal montrent une légère tendance à la hausse (leur proportion augmente avec le stress), signalant des zones de tension modérée. Enfin, les département Opérations et RH affichent des distributions marquées par quelques fluctuations. Cela pourrait être imputable à l'échantillon utilisé.

Interprétation globale

L'exploration conjointe des données met en lumière un fonctionnement contrasté : certaines dynamiques organisationnelles semblent nettes, tandis que les comportements individuels restent dispersés.

Des relations cohérentes sont observées en ce qui concerne les variables relatives à la carrière professionnel (Age, Experience, NumCompanies). Lorsque les employés sont plus âgés ou expérimentés, ils ont tendance à avoir travaillé dans un plus grand nombre d'organisations et bénéficient également davantage d'heures de formation. Cela suggère une politique d'investissement ciblée sur des profils avancés (impliquant souvent plus de responsabilités). Cette logique peut d'ailleurs être observée dans le coefficient de corrélation liant la taille des équipes et le nombre de subordonnés supervisés. Au contraire, les habitudes personnelles (sommeil, heures dédiées à la pratique de sport, distance domicile-travail) sont totalement indépendantes des caractéristiques

socioprofessionnelles. Leurs effets éventuels sur le bien-être sont donc difficilement prévisibles.

En ce qui concernant les variables cibles, le stress se caractérise par une indépendance quasi-totale vis-à-vis des autres variables. Aucune d'entre elles, si ce n'est légèrement le cas pour la variable JobSatisfaction, ne permet de l'expliquer. L'asymétrie de sa distribution et ses faibles corrélations laissent penser que des facteurs externes au jeu données l'influence. Le stress semble donc être une caractéristique plus complexe à expliquer. La satisfaction, quant à elle, affiche une structure claire. Les employés exprimant de hauts niveaux de satisfaction ont tendance à évaluer leur environnement de travail plus positivement et inversement. De manière générale, chaque catégorie (niveau d'éducation, niveau hiérarchique, ...) présente une satisfaction variée.

Modify

La phase « Modify » de la méthodologie *SEMMA* consiste à transformer les données brutes en un jeu de données cohérent et exploitable pour la construction de modèles supervisés et non supervisés. L'objectif n'est pas de modifier systématiquement l'ensemble des données, mais plutôt de garantir une utilisation optimale de ces dernières par les méthodes retenues. Concrètement, cette phase comporte diverses opérations essentielles : la gestion des données manquantes, la détection d'éventuels outliers, la discrétisation des variables continues, ainsi que la sélection des variables pertinentes.

Gestion des valeurs manquantes

Tout d'abord, comme indiqué dans la partie "Sample" et confirmé dans la phase "Explore", le jeu de données à disposition ne présente aucune valeur manquante. Par conséquent, il n'est en aucun cas nécessaire d'appliquer une quelconque technique d'imputation simple (remplacement par la moyenne, médiane ou le mode) ou avancée (remplacement en utilisant des méthodes statistiques ou de machine learning). Cette situation, particulièrement avantageuse, permet d'éviter l'introduction de biais dans les données.

Détection des outliers

Ensuite, la détection de valeurs extrêmes a été effectuée à l'aide de boxplots appliqués à l'ensemble des variables numériques. Bien que certaines observations dépassent les seuils habituels, elles demeurent cohérentes avec les réalités professionnelles. Etant donné que les modèles utilisés ne sont pas sensibles aux valeurs extrêmes, ces cas atypiques ne constituent pas un enjeu méthodologique majeur. De ce fait, aucune suppression d'outliers n'a été jugée nécessaire.

Discrétisation des variables continues

La discrétisation correspond au processus de transformation de variables continues en variables catégorielles. Cette conversion a pour objectif de simplifier l'analyse et d'accroître la robustesse des modèles, notamment pour certains algorithmes tels que les arbres de décision et les forêts aléatoires. Dans le cadre de cette étude, cette procédure de discrétisation a été envisagée pour les variables suivantes : Age, Experience, SleepHours, CommuteDistance, PhysicalActivityHours, TrainingHoursPerYear. La discrétisation réalisée a été effectuée sur base des observations et constats ressortant des analyses ayant été effectuées précédemment dans le rapport.

Age : L'analyse univariée informe quant au fait que l'échantillon présente des âges allant de 22 à 60 ans avec une médiane située aux alentours de 34 ans. En ce qui concerne l'analyse multivariée, cette dernière montre qu'une forte corrélation réside entre les variables Age, Experience, NumCompanies et TrainingHoursPerYear.

Catégories	Valeurs
Début de carrière (profils avec moins d'ancienneté et de responsabilités)	22-30 ans
Milieu de carrière (majorité bénéficiant de plus de formations)	31-45 ans
Expérimentés (profils avec plus d'ancienneté, de responsabilités et de formations)	> 45 ans

TABLE 12 – Discrétisation variable Age

Experience : L'analyse univariée présente une concentration importante des valeurs prises par la variable entre 0 et 15 ans. Pour ce qui est dans l'analyse multivariée, le discours est semblable à celui énoncé dans le paragraphe précédent destiné à l'âge.

Catégories	Valeurs
Débutants	0-3 ans
Intermédiaires	4-10 ans
Expérimentés	> 10 ans

TABLE 13 – Discrétisation variable Experience

SleepHours : Une médiane de 7 heures a été relevée sur base de l'analyse univariée, accompagnée de valeurs anormalement faibles situées autour de 4 heures. Malgré l'absence de corrélation avec les autres variables, il est intéressant de discrétiser cet attribut afin de réduire l'impact des quelques valeurs extrêmes identifiées.

Catégories	Valeurs
Temps de sommeil faible	< 6 heures
Temps de sommeil modéré (majorité de l'échantillon)	6-8 heures
Temps de sommeil élevé	> 8 heures

TABLE 14 – Discrétisation variable SleepHours

CommuteDistance : En visualisant l'évolution des boxplots des modes de transport en fonction de la distance domicile-travail, il est possible d'en retirer que les modes de déplacement traditionnels (voitures, transports en commun) sont privilégiés lorsque la distance s'avère plus élevée.

Catégories	Valeurs
Trajet court (à pied ou à vélo)	< 5 km
Trajet moyen (transports motorisés)	5-20 km
Trajet long (voiture et transport en commun)	> 20 km

TABLE 15 – Discrétisation variable CommuteDistance

PhysicalActivityHours : La médiane observée étant de 2 heures, le temps alloué à la pratique d'activités physiques au sein de l'échantillon considéré s'avère globalement faible. La segmentation va donc être effectuée sur base de la médiane.

Catégories	Valeurs
Activité faible	0-1 heure
Activité modérée	2-4 heures
Activité élevée	> 4 heures

TABLE 16 – Discrétisation variable PhysicalActivityHours

TrainingHoursPerYear : La moitié des observations présente un nombre d’heures de formation par an se situant entre 23 et 46 heures. Toutes valeurs présentes dans cet intervalle peuvent se rapporter à un niveau de formation modéré (ou attendu) en entreprise. Les valeurs situées en dessous ou au-dessus des limites du boxplot correspondent à des niveaux de formation faibles ou élevés.

Catégories	Valeurs
Formation faible	0-20 heures
Formation modérée	21-50 heures
Formation élevée	> 50 heures

TABLE 17 – Discrétisation variable TrainingHoursPerYear

Bien que la discrétisation ait été effectuée manuellement en se basant sur les analyses univariées et multivariées, il est important de souligner que la plupart des modèles, notamment les arbres de décision et les forêts aléatoires construits, affiche de meilleures performances quand la discrétisation est effectuée par les algorithmes eux-mêmes. En effet, l’utilisation du logiciel de data mining *Orange* permet aux modèles de déterminer les variables les plus discriminantes, mais surtout, dans le cas de la discrétisation, de réaliser les coupes les plus optimales possibles.

Sélection des variables pertinentes

Enfin, aucune variable n’a été supprimée à ce stade. En effet, la sélection explicite de variables dépend en grande partie du type de modélisation utilisée. Etant donné que les variables cibles (Satisfaction et Stress) sont de nature catégorielle ordinale, aucun modèle de régression (plus particulièrement linéaire) n’est envisagé. Bien au contraire, l’approche retenue repose sur des algorithmes de machine learning supervisés de classification, et plus précisément sur des arbres de décision. Ce type d’algorithme a la particularité de sélectionner automatiquement les variables jugées les plus discriminantes, ne nécessitant donc pas une suppression préalable de certains attributs. De plus, dans le cas d’un modèle non supervisé, comme le clustering envisagé ultérieurement, conserver l’ensemble des variables est tout à fait cohérent. Cela permet notamment de préserver la diversité des dimensions étudiées, favorisant ainsi la découverte de structures pertinentes dans les données. Il est à préciser que cette conservation ne doit pas être perçue comme une absence de discernement : dans le cas où certaines variables seraient jugées redondantes (multicolinéarité), elles seront éliminées afin de garantir des modèles de complexité modérée.

Model & Assess

La phase de modélisation (Model) constitue l'étape centrale de la méthodologie *SEMMA*. Son objectif est simple : concevoir des modèles supervisés capables de déterminer les niveaux de stress et de satisfaction des employés (étiquettes) en se basant sur l'ensemble des attributs définis durant les phases précédentes. A la construction des modèles supervisés s'ajoute celle des modèles non supervisés visant à regrouper des données non étiquetées (les employés) sur base de tendances identifiées.

Modèles supervisés	Arbre de décision
	Forêt aléatoire
	Régression logistique
Modèles non supervisés	Clustering hiérarchique
	K-means

TABLE 18 – Modèles supervisés et non supervisés

Comme déjà énoncé précédemment dans ce travail, la construction de nos modèles est effectuée sur base d'un ensemble d'apprentissage (Train Set) et seront ensuite évalués sur un ensemble test (Test Set). Outre l'élaboration des modèles, leur optimisation et leur amélioration seront réalisées par le biais des méthodes de bagging et de boosting. L'objectif recherché est d'obtenir des modèles ayant la meilleure capacité de généralisation possible.

A la phase de modélisation vient s'ajouter celle de l'évaluation (Assess), correspondant à la dernière étape de la méthode *SEMMA*. Elle a pour objectif d'évaluer la performance et la fiabilité des modèles conçus. Cette étape permet non seulement de s'assurer que les modèles obtenus sont en alignement avec les données, mais aussi de pouvoir comparer les différentes approches afin de sélectionner celles offrant les meilleurs résultats. A la suite de la phase « Assess », des éléments seront à disposition afin de répondre aux problématiques initialement posées en ce qui concerne le stress et la satisfaction professionnelle. En effet, l'évaluation de nos modèles permettra de formuler des recommandations claires en matière de RH sur base de l'ensemble des analyses rigoureusement menées.

Modèles supervisés

La section suivante vise à présenter les algorithmes supervisés retenus afin de déterminer les niveaux de stress et de satisfaction de n'importe quel individu. Dans le cadre de cette analyse, trois modèles supervisés ont été retenus : l'arbre de décision, la forêt aléatoire et la régression logistique. Ces modèles, complémentaires dans leur fonctionnement, feront l'objet d'une évaluation comparative afin de sélectionner celui offrant les meilleures performances.

Arbre de décision (Tree) : Ce modèle segmente la population, en élaborant une structure hiérarchique de règles décisionnelles. Il correspond à une méthode particulièrement visuelle et facilement interprétable. Le fonctionnement de l'arbre (et de l'ensemble des modèles en général)

étant fortement impacté par le réglage des hyperparamètres, il est essentiel de les fixer de manière convenable.

- **Profondeur maximale = 10** : Cette profondeur garantit un modèle flexible, capturant des relations plus complexes entre variables. Cette limite, bien que plus profonde, permet toujours d'éviter le surapprentissage excessif tout en permettant à l'arbre de présenter une capacité explicative suffisante.
- **Nombre d'instances minimum par feuille = 20** : Ce paramètre impose à l'arbre qu'une règle ne soit appliquée uniquement que si elle concerne au moins 20 employés. Cela permet de garantir robustesse et cohérence statistique dans les règles produites.

La forêt aléatoire (Random Forest) : La forêt aléatoire repose sur le bagging, consistant à partir de sous-échantillons bootstrap du jeu de données afin de concevoir des arbres de décision. A chaque nœud, une sélection de variables est réalisée afin d'obtenir des arbres différents, augmentant ainsi la variété des modèles. Les outputs finaux (étiquettes) résultent d'un vote majoritaire, rendant ce modèle plus robuste par rapport à un seul arbre de décision classique.

- **Nombre d'arbres = 500** : Un nombre d'arbres élevé permet de lisser les erreurs individuelles mais également de réduire la variance du modèle, garantissant une stabilité optimale dans les prédictions.

Régression logistique : Ce modèle statistique estime la probabilité qu'une observation appartienne à une classe donnée. Contrairement à une régression linéaire classique, la régression logistique applique une fonction sigmoïde obligeant la sortie à être comprise entre 0 et 1. Le résultat obtenu peut donc être interprété comme une probabilité d'appartenance à une classe. De plus, ce modèle est dit "boîte blanche" car il permet d'obtenir des coefficients clairs et interprétables pour chaque variable. Dans le domaine de la classification binaire, ce modèle en est une référence de par sa simplicité et sa capacité explicative élevée. Il est à noter qu'aucun paramètre de ce modèle n'a fait l'objet d'un ajustement.

Métriques de performance

Avant de mener une analyse des performances obtenues pour les modèles décrits ci-dessus, il convient de donner quelques précisions quant aux métriques de performance utilisées afin d'évaluer la capacité prédictive des différentes approches sélectionnées.

AUC (Area Under Curve) : L'aire sous la courbe ROC (taux de vrais positifs en fonction du taux de faux positifs) est une métrique essentielle afin de quantifier la performance globale d'un classificateur. Le chemin que la courbe emprunte (entre le point (0,0) et (1,1)) renseigne sur la capacité du modèle à identifier correctement les cas positifs et négatifs et ce, indépendamment du déséquilibre des classes. Plus l'AUC se rapproche de 1, meilleur est le pouvoir discriminant.

Accuracy : Correspond au pourcentage de prédictions correctes sur l'ensemble des observations. Cette métrique, bien qu'intéressante, peut s'avérer trompeuse dans le cas où les classes s'avèrent déséquilibrées.

Precision : Correspond au pourcentage de prédictions réellement positives parmi celles ayant été prédites positives.

Recall/Sensitivity : Correspond à la proportion des vrais positifs correctement identifiés par le modèle.

F1-Score : Correspond à la moyenne harmonique de Precision et Recall. Cette métrique est la référence lorsqu'il s'agit de juger de la robustesse d'un modèle. En effet, elle est fortement adaptée aux jeux de données présentant des classes déséquilibrées.

MCC (Matthews Correlation Coefficient) : Correspond à une mesure de la qualité des classifications binaires (ou multi-classes). Il évalue la corrélation entre les valeurs prédites et réelles. C'est une métrique "honnête" prenant en compte les classes déséquilibrées. Le MCC est compris entre -1 et 1 : 1 indique une prédiction parfaite, 0 indique une prédiction hasardeuse, et -1 correspond à une corrélation inverse parfaite.

Approche initiale : classification multi-classes

Concernant les variables explicatives, des tests préliminaires ont été menés en tenant compte de la discrétisation manuelle définie dans la partie "Modify". Toutefois, en comparant avec la discrétisation automatique réalisée par les algorithmes eux-mêmes, les performances obtenues lorsque les modèles déterminent les seuils de coupure sont bien meilleures. Les variables ont donc été conservées dans leur format original, laissant ainsi les algorithmes optimiser la segmentation des données.

JobSatisfaction comme variable cible

L'objectif initial lors de la construction des modèles (voir ci-dessus) était de prédire les niveaux exacts de stress et de satisfaction des employés. Pour rappel, ces variables cibles sont catégorielles et ordinales, avec des scores allant de 1 à 5. Les modèles construits ont donc tenté de déterminer le plus précisément possible ce score (stress et satisfaction) pour chaque instance d'observation. Cependant, lors de l'évaluation, les résultats obtenus se sont avérés décevants.

Modèles	AUC	Accuracy	F1-Score	Précision	Rappel	MCC
Logistic Regression	0.722	0.498	0.401	0.434	0.498	0.294
Random Forest	0.728	0.474	0.378	0.471	0.474	0.245
Arbre (Tree)	0.620	0.403	0.336	0.348	0.403	0.132

TABLE 19 – Performances des modèles avec la variable cible catégorielle JobSatisfaction

Après analyse des performances (Table 19) lorsque la variable cible est JobSatisfaction, plusieurs conclusions peuvent être tirées.

Premièrement, la performance globale affichée s'avère insuffisante. L'ensemble des modèles, même ceux étant considérés comme les plus robustes, présente une valeur pour l'accuracy plafonnant aux alentours de 0.498. En d'autres mots, cela signifie que notre modèle commet une erreur dans la prédiction du score de satisfaction une fois sur deux. Le modèle peine donc à fournir des prédictions individuellement fiables.

Deuxièmement, une difficulté de discrimination est clairement observée. Les scores F1 relativement faibles (environ 0.40) révèlent que les modèles peinent à distinguer les différentes classes. La matrice de confusion souligne le fait que la majorité des erreurs se produisent entre les classes adjacentes. Cette adversité à discriminer convenablement est sûrement due au déséquilibre résidant dans les classes. Pour rappel, la distribution de la variable JobSatisfaction révélait une situation contrastée, notamment avec des scores de 3, 4 et 5 sur-représentés. Les modèles ont donc tendance à attribuer massivement des étiquettes relatives aux classes majoritaires (3, 4 et 5) et ce, en dépit des autres classes. En effet, bien que l'AUC reste relativement correcte (car peu sensible au déséquilibre entre les classes), le MCC, qui prend en compte les classes déséquilibrées, s'avère quant à lui assez faible.

En conclusion, les faibles performances misent en évidence valident l'hypothèse selon laquelle la "frontière" entre les niveaux de satisfaction intermédiaires est trop subjective et bruitée pour être modélisée efficacement avec les données actuelles. De plus, le déséquilibre dans le jeu de données utilisé semble exercer une influence majeure sur les valeurs des métriques utilisées. Ce constat d'échec a motivé un changement de méthodologie afin d'obtenir des résultats plus fiables.

Stress comme variable cible

Comme évoqué précédemment, le but initial des modèles est de prédire le niveau de stress et de satisfaction des employés. Néanmoins, lors de l'analyse exploratoire menée au début de ce travail, il en est ressorti que la variable Stress était peu influencée par les autres variables. En revanche, l'attribut relatif au stress exerce un impact important sur la satisfaction des employés. Pour cette raison, il a été décidé de conserver cette variable dans la prédiction de JobSatisfaction.

Modèles	AUC	Accuracy	F1-Score	Précision	Rappel	MCC
Logistic Regression	0.584	0.617	0.486	0.475	0.617	0.053
Random Forest	0.597	0.623	0.482	0.621	0.623	0.076
Arbre (Tree)	0.547	0.597	0.477	0.410	0.597	0.011

TABLE 20 – Performances des modèles avec la variable cible catégorielle Stress

Après analyse des résultats (voir Table 20), le constat est simple : les performances des modèles pour le stress et la satisfaction sont globalement similaires, à l'exception du MCC. La baisse notable de cette métrique indique une perte de corrélation entre les prédictions et les valeurs

réelles (perte de cohérence dans la structure des prédictions). Cette dégradation des performances ne provient pas des modèles en tant que tels, mais d'un facteur exerçant une influence sur l'équilibre des classes ou de la capacité du modèle à identifier les relations entre les variables.

Nouvelle approche : classification binaire

JobSatisfaction comme variable cible

Au vu des performances décevantes précédemment observées pour nos différents modèles, et après analyses complémentaires, la solution binaire s'est révélée la plus pertinente. En effet, la variable JobSatisfaction, anciennement catégorielle et ordinale, devient maintenant binaire. Elle prend la valeur 0 pour les employés peu, voire moyennement satisfaits (JobSatisfaction = [1-3]), et 1 pour les employés satisfaits (JobSatisfaction = [4-5]). Techniquement, cette transformation a été opérée via le constructeur de variables "Formula" (via le logiciel Orange) en appliquant la règle qui suit.

$$Satisfaction_Binaire = \begin{cases} 1 & \text{si } JobSatisfaction \geq 4 \\ 0 & \text{si } JobSatisfaction < 4 \end{cases}$$

En ayant recours à cette nouvelle méthodologie, cela permet de solutionner le problème précédemment évoqué : la difficulté des modèles à distinguer efficacement les différentes classes. Cette nouvelle approche nécessite un compromis que nous avons jugé pertinent : binariser la variable JobSatisfaction simplifie la prédiction renvoyée. Le modèle informe uniquement sur le fait qu'un employé soit satisfait ou pas, sans fournir de score exact. Il s'agit donc d'un compromis raisonnable entre finesse de prédiction et fiabilité. Il est important de garder en tête que l'objectif managérial final n'est pas de connaître la note attribuée à la satisfaction à la décimale près, mais d'identifier clairement les groupes "à risque" vs "satisfaits". La priorité est donc davantage donnée à la fiabilité de détection (satisfait ou pas) plutôt qu'à la finesse des prédictions. Il s'avère que le changement de stratégie effectué a porté ses fruits : comme le montre le tableau comparatif ci-dessous, la transition vers une cible binaire a permis une amélioration significative des performances.

Modèle	AUC	Accuracy	F1-Score	Précision	Rappel	MCC
Logistic Regression	0.779	0.740	0.737	0.739	0.740	0.464
Random Forest	0.788	0.726	0.714	0.733	0.726	0.435
Arbre (Tree)	0.659	0.648	0.638	0.643	0.648	0.265
Gradient Boosting	0.781	0.739	0.732	0.741	0.739	0.461

TABLE 21 – Performances des modèles avec la variable cible binaire JobSatisfaction

La transformation de la variable cible (JobSatisfaction) en variable binaire a permis une augmentation significative de la performance globale des modèles mobilisés (voir Table 21). La binarisation de la variable cible permet de passer d'une précision d'environ 49% à 74% avec la

régression logistique, rendant désormais le modèle fiable pour trois quarts des employés. Avec un Recall de 0.74, le modèle est désormais capable d'identifier correctement près de 74% des profils satisfaits, le rendant opérationnel et pertinent dans un contexte managérial. Malgré une nette augmentation de la performance pour l'ensemble des modèles employés (valeurs situées autour de 0.7), le MCC reste, quant à lui, relativement faible (valeurs situées autour de 0.46). Cela relève du déséquilibre persistant évoqué précédemment entre les classes. Cependant, il est important de noter que les valeurs affichées pour cette métrique ont littéralement doublé par rapport à notre approche initiale.

Stress comme variable cible

Bien que la variable cible Stress ne soit pas significativement impactée par un grand nombre de variables, la méthode binaire lui a également été appliquée. Elle prend la valeur 0 pour les employés peu stressés (Stress : [1-2]), et 1 pour les employés stressés (Stress = [3-5]). Les seuils retenus, c'est-à-dire [1-2] pour les employés peu stressés et [3-5] pour les employés stressés, ont été déterminés sur base de l'allure de la distribution, comme cela a été fait pour JobSatisfaction. Cette transformation a été créée avec le constructeur de variables "Formula" (via le logiciel Orange), en appliquant la règle logique qui suit.

$$Stress_Binaire = \begin{cases} 1 & \text{si } Stress \geq 3 \\ 0 & \text{si } Stress < 3 \end{cases}$$

Modèle	AUC	Accuracy	F1-Score	Précision	Rappel	MCC
Logistic Regression	0.613	0.785	0.701	0.712	0.785	0.057
Random Forest	0.611	0.783	0.691	0.618	0.783	-0.030
Arbre (Tree)	0.526	0.755	0.696	0.668	0.755	0.009
Gradient Boosting	0.595	0.788	0.708	0.742	0.788	0.103

TABLE 22 – Performances des modèles avec la variable cible binaire Stress

Sans grande surprise et conformément aux précédentes analyses, les résultats affichés pour la variable Stress binarisée sont globalement en deçà de ceux observés pour la satisfaction (voir Table 22). Certes, l'ensemble des métriques de performances ont connu une amélioration notable, mais cette tendance ne s'applique pas au MCC. Bien au contraire, cette mesure présente une dégradation importante, affichant même une valeur négative (-0.030) pour le modèle de la forêt aléatoire, là où JobSatisfaction a vu ses performances doubler.

Amélioration des modèles

Contrairement aux méthodes utilisées jusqu'à présent, celle du Gradient Boosting a été mise en œuvre dans le cadre de cette nouvelle approche avec un nombre d'arbres fixé à 100 (voir Table 21 & 22). Contrairement à la forêt aléatoire où les arbres sont construits en parallèle et où

les prédictions résultent d'un « vote », le Gradient Boosting consiste à construire de manière séquentielle des modèles faibles, c'est-à-dire des arbres de décision peu profonds. En d'autres mots, chaque nouvel arbre construit a pour objectif de corriger les erreurs des arbres précédents. En ayant recours à cette méthode, des résultats similaires, voire supérieurs, à ceux obtenus avec les modèles antérieurs sont observés.

Visualisation et validation des variables discriminantes

Afin de valider la cohérence des modèles, une représentation de l'arbre de décision a été générée, limitée à une profondeur de 3 pour garantir la lisibilité du visuel. Bien que l'arbre dans sa forme la plus simple soit nettement moins performant que la forêt ou la régression logistique, sa structure hiérarchique offre un aperçu unique des facteurs de décision. Cela permet notamment de déterminer quelles sont les variables impactant le plus la satisfaction des employés.



FIGURE 7 – Arbre de Décision pour la variable cible binaire JobSatisfaction

L'examen du nœud racine (sommet de l'arbre) révèle que la variable WorkLoad est le discriminant principal pour déterminer la satisfaction. Cela corrobore les analyses exploratoires initiales au cours desquelles une forte corrélation entre cette dimension et la satisfaction globale avait été mise en évidence. Les nœuds suivants divisent la population selon la variable WorkEnv, puis WLB. Il est intéressant de noter que l'arbre sélectionne naturellement ces variables comme étant les plus informatives, validant ainsi la pertinence de nos attributs sans intervention humaine. Cette convergence entre l'analyse statistique (univariée et multivariée) et l'apprentissage machine (arbre de décision) renforce la validité des conclusions.

Sélection du modèle final

Suite au changement de méthodologie effectué, les performances de l'ensemble des modèles se sont drastiquement améliorées. Toutefois, l'arbre de décision reste en retrait, affichant des performances significativement inférieures. Dans la quête du meilleur résultat, bien que les performances de la forêt aléatoire, de la régression logistique et du Gradient Boosting soient relativement similaires, le choix de la régression comme modèle final paraît être le plus pertinent. Ce choix est motivé par son caractère "explicable" (white box) : contrairement aux modèles de boîtes noires (forêt aléatoire), la régression permet d'identifier les coefficients d'influence de chaque variable, offrant ainsi une réponse à la problématique d'identification des leviers d'action.

Modèles non supervisés

La section qui suit vise à présenter les algorithmes non supervisés retenus afin d'identifier les structures sous-jacentes du jeu de données et de regrouper les employés selon des caractéristiques similaires. Dans cette partie de l'analyse, deux modèles de machine learning non supervisés ont été employés : le clustering hiérarchique et le K-means. Ces méthodes, complémentaires, permettront de déterminer des profils homogènes et d'identifier les patterns qui les différencient. Ces deux approches feront l'objet d'une évaluation comparative afin de prendre une décision quant au modèle le plus adapté à la structure des données.

Avant toute construction, il est important de souligner que les variables, qu'elles soient catégorielles ou numériques, ont fait l'objet d'une transformation. En effet, les variables catégorielles ont été modifiées grâce à un one hot encoding, permettant aux algorithmes de distance mobilisés d'exploiter ces attributs existant désormais sous forme numérique. De plus, les variables qui, initialement, étaient numériques ont été normalisées entre 0 et 1, afin d'éviter que les échelles n'influencent disproportionnellement les calculs de distance. Cette étape est particulièrement importante, notamment lorsque la distance utilisée est une distance euclidienne. En effet, cette dernière s'avère fortement sensible aux différences d'amplitude.

Cependant, une exception a été faite pour la variable numérique `TrainingHoursPerYear`. Ce choix a été opéré en connaissance de cause : la variable présente une dispersion importante, mettant en évidence des différences structurelles entre les employés, en fonction de leur niveau hiérarchique ou encore de leur ancienneté au sein de l'organisation. En normalisant cette variable, cela aurait comme effet de réduire ces différences, alors qu'il s'agit d'un attribut organisationnel structurant. Il a donc été décidé de conserver l'amplitude significative de `TrainingHoursPerYear` dans le but de préserver son pouvoir explicatif.

Clustering hiérarchique

Le clustering hiérarchique consiste en la construction d'une hiérarchie de clusters, allant d'individus isolés à des groupements plus importants. En ayant recours à ce type de modèle, il est possible d'obtenir une visualisation claire des sous-groupes d'employés, notamment à l'aide d'un dendrogramme. Comme énoncé précédemment, la mesure de distance utilisée correspond à la distance euclidienne. Le choix de cette métrique se justifie par le fait qu'elle constitue la mesure de distance de référence pour la méthode de linkage de Ward. En effet, cette dernière consiste à minimiser l'inertie intra-groupe et cherche à former des clusters compacts et bien séparés. Ce type de liaison est souvent efficace pour les variables quantitatives, mais sensible aux valeurs aberrantes, ce qui n'est pas le cas dans notre jeu de données, comme explicité dans la partie « Modify ».

Analyse du clustering hiérarchique




FIGURE 8 – Dendrogramme lié au clustering hiérarchique

Le dendrogramme construit met en lumière la formation de cinq clusters (C1 à C5), présentant chacun une homogénéité tout à fait différente. Les groupes C1 et C2 sont relativement compacts avec des fusions intervenant aux « premiers niveaux ». Le cluster 3, quant à lui, présente une population plus diversifiée caractérisée par une zone plus étendue. Enfin, en ce qui concerne les groupes C4 et C5, ils présentent une cohésion interne notable.

Le placement du niveau de coupure, situé légèrement en-dessous d'une hauteur de 200, est pleinement justifié : la pratique professionnelle veut que la coupure soit positionnée avant une perte trop importante de qualité (perte d'inertie). En examinant le dendrogramme, au-dessus de 200, des sauts brutaux dans la hauteur des fusions sont clairement observables. Placer une coupure au-dessus de 200, c'est prendre le risque de subir une perte massive de l'inertie intra-cluster. L'objectif étant de former des groupes semblables et interprétables, le choix de ce placement semble tout à fait adéquat. Le seuil retenu correspond à la logique de préservation maximale de l'information recherchée en classification hiérarchique.

C1	C2	C3	C4	C5	Moyenne
0.582	0.379	0.513	0.684	0.649	0.5614

TABLE 23 – Scores de silhouette par cluster et moyenne globale (clustering hiérarchique)

Afin de mesurer simultanément la cohésion intra-cluster et la séparation inter-clusters, le score de silhouette a été calculé pour chacun des cinq clusters (C1 à C5), ainsi que le score moyen global (Table 23). Plus le score de silhouette est élevé, c'est-à-dire proche de 1, plus les observations sont proches de leur propre cluster et éloignées des clusters avoisinants. Avec un score de silhouette moyen de 0.5614, les résultats obtenus reflètent un partitionnement de qualité satisfaisante. En effet, une valeur supérieure à 0.5 est généralement considérée comme étant un bon résultat.

Cependant, il est intéressant de tenir compte des disparités existantes entre les groupes formés. Les clusters C4 (0.684) et C5 (0.649) présentent une bonne homogénéité interne ainsi qu'une bonne séparation par rapport aux autres groupes. Ce constat appuie ce qui a été avancé dans l'analyse du dendrogramme, où les clusters semblaient compacts et individualisés. Les employés au sein de ces groupes sont donc clairement identifiables. Concernant le cluster C1 (0.582), il présente un score convenable, légèrement supérieur à celui de la silhouette moyenne. Bien qu'inférieur à celui du cluster C4 et C5, le score affiché par le groupe C1 traduit tout même une structure interne cohérente.

Par rapport aux groupes discutés précédemment, le cluster C3 (0.513) présente un score quelque peu dégradé. La population, bien que hétérogène, présente tout de même quelques observations proches de la frontière avec les autres groupes. Les conclusions faites quant aux clusters C1 et C3 peuvent d'ailleurs être confirmées à travers le dendrogramme (plus grandes dispersions observées pour ces groupes). Enfin, le cluster C2 (0.379) est celui qui affiche un score de silhouette plus décevant. Cette valeur, certes positive, renseigne sur une séparation moins claire et un potentiel chevauchement avec des groupes voisins. Au vu du résultat obtenu, il faudra agir avec prudence lorsqu'il s'agira de caractériser ce groupe.

De manière générale, les scores de silhouette obtenus confirment la pertinence du nombre de clusters formés. Il est tout de même important de souligner que les groupes formés affichent des niveaux de qualité variables. Cette information sera donc à prendre en compte lorsqu'il s'agira d'analyser les groupes en eux-mêmes.

K-means

Avant de caractériser les clusters, il est nécessaire de se pencher sur une seconde approche qui est celle de l'algorithme du K-means. Le K-means, comme c'est le cas pour le clustering hiérarchique, a pour objectif de partitionner des observations en K groupes distincts (K étant défini a priori). Pour ce faire, il cherche à diminuer au maximum l'inertie intra-cluster, c'est-à-dire la somme des distances entre chaque observation et le centroïde du cluster auquel elle appartient. Le fonctionnement de l'algorithme est le suivant : K centroïdes sont d'abord initialisés (dans notre cas cela se fait via une initialisation aléatoire). Ensuite, chaque observation est assignée à un centroïde (le plus proche) sur base du calcul de la distance euclidienne. Les centroïdes sont recalculés et le processus se répète jusqu'à observer une stabilisation des clusters formés ou jusqu'à atteindre le nombre maximal d'itérations fixé en amont.

Analyse du K-means

Dans le cadre de cette étude, le K-means a été appliqué en faisant varier le nombre de clusters de 2 à 7. Pour ces différents partitionnements, le score de silhouette a été calculé et ce, de manière automatique par le logiciel Orange. En comparant les scores obtenus, cela permet de déterminer la valeur de l'hyperparamètre K offrant un compromis optimal entre cohésion intra-clusters et la séparation inter-clusters.

2	3	4	5	6	7
0.546	0.473	0.492	0.512	0.439	0.400

TABLE 24 – Scores de silhouette selon le nombre de clusters (K-means)

En analysant les résultats (Table 24), le score de silhouette optimal (0.546) semble être celui obtenu lorsque la valeur de l'hyperparamètre vaut 2. Ce résultat se traduit par deux groupes d'employés distincts présentant des structures différenciées. Cependant, il est important de garder en tête que la formation de deux clusters peut s'avérer être une solution trop agrégée, limitant ainsi la finesse des profils identifiés.

Lorsque le nombre de clusters augmente, une dégradation des scores de silhouette est clairement observée. Le score atteint 0.473 quand K est égal à 3 et remonte légèrement lorsqu'il vaut 4 (0.492). Parmi les scores à granularité plus fine, celui correspondant à une partition en 5 clusters est le plus élevé, égal à 0.512. Le résultat affiché est, certes, inférieur à celui obtenu pour K égal à 2, mais garantit tout de même des clusters avec une structure interprétable. En ce qui concerne les scores de silhouette au-delà de 5 clusters, ces derniers semblent décroître progressivement, traduisant une perte de qualité du partitionnement.

L'analyse des résultats obtenus en ayant recours à l'algorithme du K-means souligne un compromis entre qualité statistique et clarté d'interprétation. La formation de 2 clusters maximise le score de silhouette mais, comparativement à la partition en 5 groupes, elle n'offre pas la « richesse analytique » nécessaire à une caractérisation plus fine des profils. Ce constat est d'ailleurs rassurant étant donné qu'il rejoint le nombre de groupes défini dans la méthode du clustering hiérarchique.

Choix du modèle final

Sur base des analyses menées, la méthode retenue dans le cadre de la phase de construction des modèles non supervisés est celle du clustering hiérarchique. Ce choix est motivé par divers éléments. Dans un premier temps, le score de silhouette moyen obtenu dans le cadre du clustering hiérarchique est supérieur à celui affiché par l'algorithme du K-means et ce, pour un même nombre de clusters formés, égal à cinq (0.5614 // 0.512). Ensuite, le dendrogramme laisse place à une justification visuelle et méthodologique du nombre de clusters, ce qui n'est pas le cas du K-means. En effet, avec ce dernier, la phase exploratoire est totalement absente et les résultats obtenus sont majoritairement influencés par la valeur de l'hyperparamètre K (choisi a priori)

et par l'initialisation des centroïdes (choisi a priori également). Enfin, concernant le nombre de clusters à former, il semble cohérent de le fixer à cinq. Cela est d'ailleurs confirmé par la tendance des deux méthodes employées à converger vers cette solution.

Caractérisation des clusters

Maintenant que le modèle final a été sélectionné et que nombre de clusters à former est fixé, il convient d'analyser plus précisément les différents groupes formés. L'objectif de cette étape est de pouvoir caractériser les profils d'employés résidant au sein de ces ensembles. Cette phrase est absolument essentielle car elle permet à une organisation, et plus spécifiquement aux départements RH, de rendre les résultats du clustering opérationnels et exploitables. L'analyse qui va suivre consistera à comparer les clusters en se basant sur les principales variables explicatives du modèle. La caractérisation effectuée enrichira la compréhension interne de l'organisation et permettra aux composantes RH de dégager des éléments utiles à la prise de décision managériale.

Le cluster C1 du fait des valeurs importantes prises par les variables Experience et Age se caractérise par des employés affichant des niveaux d'expérience et d'ancienneté élevés. Les profils composant ce groupe occupent majoritairement des postes de niveau Lead, reflétant un rôle central au sein de l'organisation. Cette position de leader est notamment appuyée par des valeurs également importantes de TeamSize et NumReports. En d'autres mots, les individus appartenant à C1 ont tendance à gérer des équipes conséquentes et à avoir plusieurs collaborateurs à leur charge. De plus, pour ce type d'individu, le nombre d'entreprises fréquentées durant la carrière professionnelle (NumCompanies) est relativement élevé. Le volume de formation annuel alloué à ces personnes s'avère conséquent (TrainingHoursPerYear compris entre 54 et 64 heures), traduisant une implication importante dans des formations potentiellement liées aux exigences élevées de la fonction occupée. Toutefois, ni la situation maritale ni le niveau d'éducation ne révèlent de tendance marquée, si ce n'est le fait que les profils appartenant à ce cluster ont un niveau d'éducation strictement supérieur aux études secondaires (High School = 0).

Le cluster C2, présentant un score de silhouette plus faible par rapport aux autres clusters (0.379), semble afficher des valeurs fortement diversifiées sur l'ensemble des variables analysées. Cette diversité peut notamment être observée pour les variables relatives à l'âge, à l'expérience, ou encore au niveau hiérarchique occupé. De même, les indicateurs organisationnels tels que TeamSize, NumCompanies et NumReports sont relativement étendus. Concernant la variable TrainingHoursPerYear, la majorité des employés semblent bénéficier d'un volume important de formations (valeurs comprises entre 39 et 64 heures). L'absence de tendances concernant le statut marital et le niveau d'éducation semble appuyer l'idée selon laquelle le cluster est peu structuré. Comme déjà énoncé précédemment, le niveau de silhouette faible qui avait été observé pour ce cluster semble grandement impacter l'homogénéité du groupe formé.

Le cluster C3 rassemble des profils occupant en grande majorité des postes de niveau Mid. Cette idée est renforcée par des valeurs intermédiaires prises par l'âge et le niveau d'expérience. Cela

suggère que ces individus se situent dans la phase de consolidation de leur carrière professionnelle (situés entre un niveau Junior et Senior). La taille des équipes dans lesquelles ces employés sont impliqués est modérée et la variable NumReports est majoritairement nulle. Ces constats renforcent le fait que l'implication managériale de ces individus est encore limitée. Le volume de formation annuelle dont dispose ces profils est modéré (situé entre 30 et 40 heures), reflétant un besoin d'acquisition de nouvelles compétences, possiblement en lien avec une envie d'évolution vers davantage de responsabilités. Comme pour le cluster C1, les individus appartenant à ce cluster ont un niveau d'éducation strictement supérieur aux études secondaires (High School = 0).

Le cluster C4 se caractérise par des individus étant en début de carrière. Les personnes qui constituent ce groupe sont plutôt jeunes, affichant des valeurs faibles pour la variable relative à l'âge et l'expérience. Le niveau hiérarchique occupé est celui de Intern/Fresher, appuyant l'idée selon laquelle ces employés sont nouveaux dans l'organisation. Ils sont tous, sans exception, célibataires, et manifestent des valeurs pour NumCompanies et NumReports égales à 0 (aucune autre entreprise connue antérieurement et aucune responsabilité au sein de l'organisation actuelle). Aucun rôle décisionnel n'est joué par ce type de profil, bien qu'il soit présent dans des équipes de grandes tailles (TeamSize élevé). Se situant probablement dans leur phase d'intégration professionnelle, le volume annuel alloué aux formations est faible (proche des 10 heures).

Le cluster C5 rassemble des employés majoritairement Junior. Ces profils, de manière semblables à ce qui a pu être observé dans le cluster C4, sont relativement jeunes et disposent d'un niveau d'expérience encore limité (bien que supérieur au cluster C4). Les profils dont il est question ici travaillent au sein de petites équipes et disposent de responsabilités limitées, voire inexistantes (NumReports = 0). Contrairement au groupe 4, le nombre d'entreprises fréquentées précédemment n'est pas nul, bien qu'assez faible. Concernant le volume de formation annuelle, il s'avère modéré (entre 20 et 23 heures), traduisant un besoin de développement professionnel. A nouveau, en opposition avec ce qui a pu être observé pour le cluster 4, le statut marital des individus présents dans le cluster 5 est plus diversifié. Cela traduit une population plus mature sur le plan personnel.

Clusters	Description des profils
C1	Profils Seniors et Leads à forte responsabilité, occupant des fonctions clés et jouant un rôle structurant dans l'organisation.
C2	Interprétation prudente : groupe résiduel aux trajectoires professionnelles multiples.
C3	Profils stables professionnellement, ayant une expérience conséquente mais cherchant à évoluer sur l'échelle des postes.
C4	Employés de jeune âge occupant des postes de niveau Intern/Fresher et étant en pleine phase d'intégration.
C5	Profils Juniors déjà implantés dans l'entreprise et appelés à évoluer vers des postes intermédiaires.

TABLE 25 – Description des profils par cluster

Synthèse globale

Le clustering hiérarchique effectué met en lumière une progression cohérente des profils. Ces derniers vont de jeunes entrants (C4), aux juniors intégrés (C5), aux profils intermédiaires (C3), jusqu'aux individus occupant des postes Senior et Lead (C1). Seul le cluster C2 se distingue de par son hétérogénéité plus marquée, principalement impactée par son score de silhouette faible. Cette structure constitue une base solide pour la prise de décisions managériales, notamment en termes de gestion de carrière, de formation et de développement professionnel.

Synthèse de la fouille des données

Cette section a pour objectif de présenter une synthèse de la fouille de données réalisée, en parcourant les différentes étapes mise en œuvre dans le cadre de la méthodologie *SEMMA*. Elle discute non seulement des choix opérés, mais également des résultats obtenus.

Sample

Pour cette première phase, le jeu de données sélectionné est "Employee Survey". Ce dernier contient 3025 instances, 23 variables (de tous types) et aucune valeur manquante, ce qui en fait un jeu de données cohérent et suffisamment diversifié. Dans une démarche de construction et d'évaluation de nos modèles, les données ont été divisées selon la règle du 80-20 : 80% des données sont destinés à l'entraînement, tandis que les 20% restants sont dédiés aux tests.

Explore

La phase « Explore » est, comme le nom l'indique, dédiée à une exploration complète des données, se traduisant par une analyse approfondie, couvrant successivement les approches univariée (distributions et boxplots) et multivariée (matrices de corrélation et de contingence). Suite à ces explorations, diverses conclusions ont été tirées.

Concernant l'analyse univariée, elle révèle une population majoritairement masculine et jeune, occupant des postes nécessitant une certaine expérience (structure mature constituée de profils expérimentés). Certains départements sont fortement représentés tels que la Finance, l'IT ou encore les Opérations, là où d'autres le sont beaucoup moins, comme le Customer Service et le HR. Le statut marital des employés se répartit majoritairement entre personnes mariées et célibataires, et une grande partie des effectifs présente un niveau d'éducation se limitant au bachelier. L'examen des variables ordinales révèle des distributions relativement équilibrées, bien que certaines valeurs se démarque légèrement. C'est notamment le cas pour la variable relative à l'équilibre entre vie privée et vie professionnelle, où les scores observés sont majoritairement situés en 4 et 5. Le même constat est observé pour la variable relative à l'environnement de travail, mais cette fois les scores sont davantage concentrés en 3 et 5. Durant l'étude des variables continues, des tendances importantes se dégagent. En effet, la distance domicile-travail varie fortement, influençant les modes de transport utilisés. De plus, l'investissement en formation, lui aussi assez étendu, semble inégalement réparti selon le niveau hiérarchique occupé. Une autre tendance frappante concerne le temps consacré à la pratique d'activité physique. Le jeu de données présente des valeurs relativement faibles, bien qu'une minorité affiche un niveau d'activité légèrement plus élevé. Du côté des variables cibles, la distribution de la satisfaction révèle une situation contrastée mais positive avec une grande partie des employés attribuant une note élevée, en particulier un score de 4 et 5. La situation est nettement différente lorsqu'il s'agit du stress. La distribution est clairement asymétrique avec des niveaux de stress principalement faibles (modalité 1 majoritaire).

Du côté de l'analyse multivariée, l'utilisation des matrices de corrélation de Pearson, de Spearman, ainsi que des matrices de contingence a permis de déceler des tendances notables entre les variables. Des relations fortes sont constatées entre les variables relatives à l'âge, l'expérience, le nombre d'entreprises fréquentées antérieurement, la taille des équipes, le nombre de subordonnés et le volume annuel de formation. Ces corrélations fortes sont tout à fait justifiées : un employé plus âgé aura logiquement plus d'expérience professionnelle et aura tendance à avoir changé plus souvent d'employeur au cours de sa carrière. De plus, les employés aux niveaux hiérarchiques élevés ont généralement tendance à manager des équipes de plus grandes tailles et donc d'avoir davantage de subordonnés à leur charge. Enfin, les employés plus âgés (ou plus expérimentés) réalisent davantage d'heures de formation annuelle. Cela peut notamment s'expliquer par l'organisation interne, où les collaborateurs exerçant plus de responsabilités se voient offrir plus de formations. Du côté des variables cibles, la satisfaction professionnelle suit les hypothèses formulées initialement. En effet, cette dernière est positivement liée à la qualité de l'environnement de travail et à l'équilibre vie privée / professionnelle, tandis qu'elle est freinée par une charge de travail élevée. À l'inverse, le stress et les habitudes personnelles (sommeil, activité physique, distance domicile-travail) apparaissent comme étant complètement déconnectés des facteurs professionnels et organisationnels. Le stress, en particulier, affiche une très faible corrélation avec l'ensemble des autres variables présentes dans le jeu de données. Cette analyse suggère que, si la trajectoire professionnelle des employés est clairement structurée, le stress exprimé semble, quant à lui, dépendre de facteurs externes.

Modify

A la suite de l'exploration des variables vient la phase « Modify ». Celle-ci se voit être moins exigeante, entre autres grâce à l'absence de valeurs manquantes au sein du jeu de données. De plus, aucune suppression d'outliers n'a été jugée nécessaire. Ce choix s'explique par le fait que, bien que certaines observations dépassent les seuils habituels, elles demeurent cohérentes avec les réalités professionnelles. Concernant la discrétisation des variables continues, elle a été effectuée sur base des analyses univariées et multivariées. Cependant, les coupures effectuées manuellement ne sont pas celles retenues par nos modèles. En effet, l'utilisation du logiciel de data mining Orange permet aux modèles de déterminer les variables les plus discriminantes, mais surtout, dans le cas de la discrétisation, de réaliser les coupes les plus optimales possibles.

Model & Assess

Au cours des phases « Model » et « Assess », six modèles ont été développés : arbre de décision, forêt aléatoire, régression logistique, gradient boosting, K-means et le clustering hiérarchique.

Une fois les paramètres critiques des modèles supervisés (arbre de décision, forêt aléatoire, régression logistique, gradient boosting) établis, chacun d'eux a été entraîné sur le set d'apprentissage initialement établi (80% du total des données). Une fois la construction des modèles réalisée, il a été question d'évaluer ces derniers sur le set de test (20% du total des données). Il s'est avéré

que les résultats obtenus étaient assez décevants lorsque les variables cibles étaient catégorielles (situation avant transformation). Afin de répondre à ce manque de performance, un arbitrage a été effectué et la décision de transformer les variables cibles catégorielles en variables binaires a été retenue. Bien que réduisant la finesse des prédictions obtenues, cette stratégie a permis d'en améliorer la robustesse et l'interprétabilité. Le choix de la régression comme modèle final paraît être le plus pertinent. Cette décision est motivée par son caractère "explicable" (white box) : contrairement aux modèles de boîtes noires (forêt aléatoire), la régression permet d'identifier les coefficients d'influence de chaque variable, offrant ainsi une réponse à la problématique d'identification des leviers d'action.

Après analyse conjointe des modèles non supervisés construits (K-means et clustering hiérarchique), la segmentation du jeu de données en cinq clusters semblait être la plus pertinente. Le modèle retenu est celui du clustering hiérarchique et ce, pour plusieurs raisons. Dans un premier temps, le score de silhouette moyen obtenu dans le cadre du clustering hiérarchique est supérieur à celui affiché par l'algorithme du K-means et ce, pour un même nombre de clusters formés, égal à cinq (0.5614 // 0.512). Avec un score tel que celui-là, le partitionnement est de qualité suffisante. En effet, une valeur supérieure à 0.5 garantit des clusters ayant une structure suffisamment interprétable. Ensuite, le dendrogramme laisse place à une justification visuelle et méthodologique du nombre de clusters, ce qui n'est pas le cas du K-means.

La caractérisation des clusters est la suivante : le cluster C1 est composé de profils Senior et Lead âgés, grandement expérimentés et devant gérer des équipes conséquentes avec un grand nombre de subordonnés à leur charge. Le nombre d'entreprises fréquentées durant leur carrière et le volume annuel de formation s'avèrent, eux aussi, particulièrement importants. Concernant leur niveau d'éducation, il est strictement supérieur à l'enseignement secondaire. Le cluster C2, quant à lui, se caractérise comme étant un groupe composé de profils plus hétérogènes. Les variables considérées varient fortement d'un individu à l'autre, appuyant l'idée de profils disparates. Néanmoins, un point commun à ce cluster apparaît et concerne le volume d'heures de formation annuel, étant assez élevé et variant entre 39 et 64 heures. Contrairement aux autres groupes, celui-ci ne possède pas de "signature" particulière. Le cluster C3 se compose en grande majorité de profils occupant un poste Mid (situé entre Junior et Senior) et affichant un âge et un niveau d'expérience intermédiaires. L'implication managériale de ces individus semble encore limitée de part le nombre d'employés à charge qui s'avère nul. Concernant le volume de formation annuelle, il est modéré (autour de 30 à 40 heures), reflétant un besoin d'acquisition de nouvelles compétences. Le cluster C4 se caractérise par des individus en début de carrière, se trouvant donc dans leur phase d'intégration professionnelle (Intern/Fresher). Ces personnes affichent des valeurs pour l'âge et l'expérience très faibles. Cette tendance est également observable en ce qui concerne le nombre d'entreprises fréquentées antérieurement et le nombre de subordonnés à charge (les deux variables affichent des valeurs nulles). Le cluster C5 rassemble des employés majoritairement Junior. Comme pour le cluster C4, les individus composant ce groupe sont jeunes et présentent un niveau d'expérience encore limité (bien que supérieur à C4). Contrairement au groupe C4,

les employés travaillent ici dans des équipes réduites et certains ont déjà fréquentés d'autres entreprises auparavant. De plus, le nombre d'heures allouées à la formation est annuellement plus élevé pour ce groupe comparativement à celui des Intern/Fresher discuté précédemment.

Discussion des résultats : problématiques et hypothèses

L'application rigoureuse de la méthodologie *SEMMA* avait pour objectif de répondre aux problématiques initialement posées et d'évaluer de manière critique les hypothèses formulées. Pour rappel, les problématiques énoncées cherchaient à comprendre les déterminants du stress et de la satisfaction, ainsi qu'à diviser la population en profils homogènes interprétables par les RH. En ce qui concerne les hypothèses, elles étaient majoritairement intuitives. Cependant, seule une analyse combinant exploration des données et modélisation permet de tester leur validité.

Problématique 1 : Stress au travail

La première problématique cherchait à déterminer quels étaient les facteurs expliquant le stress et permettant de le prédire. En réponse à cette problématique, l'hypothèse suivante avait été formulée : Une charge de travail élevée, un manque de temps de sommeil, un faible niveau d'activité physique et un piètre équilibre entre vie privée et vie professionnelle participent à la génération du stress, et ces facteurs permettent de prédire le stress ressenti.

Du côté de l'analyse exploratoire, les données ont rapidement réfuté l'hypothèse posée. Ni la charge de travail ni l'équilibre vie privée / vie professionnelle ne présentent de relation marquée avec les niveaux de stress observés. Les matrices de contingence informent quant au fait que la distribution du stress reste homogène et ce, quelles que soient les modalités des variables Workload et WLB. Pour ce qui est des variables continues, c'est-à-dire celles relatives au sommeil et à la pratique d'activité physique, aucune corrélation avec le stress n'est constatée.

Concernant la phase de modélisation, elle confirme les propos avancés jusqu'à maintenant. Les modèles construits s'avèrent peu performants lorsqu'il s'agit de prédire le niveau de stress, bien que la binarisation de la variable ait permis d'améliorer quelque peu les résultats de prédiction. En effet, après binarisation, même si certaines métriques comme l'accuracy peuvent sembler acceptables, d'autres indicateurs comme le MCC indiquent une absence de pouvoir discriminant.

La convergence des constats issus de l'analyse exploratoire et de la modélisation amène à formuler une conclusion simple : l'hypothèse formulée est réfutée sur le plan empirique. Le stress semble ne pas pouvoir être expliqué à partir des variables du jeu de données à disposition. D'autres facteurs, externes, relatifs à la pression psychologique, aux événements personnels ou encore au contexte organisationnel influencent potentiellement davantage le stress ressenti par un individu. Le problème n'est donc pas lié au choix ou à la manière dont les modèles ont été développés, mais plutôt à un manque de variables explicatives dans les données.

Problématique 2 : Satisfaction professionnelle

La deuxième problématique portait sur les déterminants de la satisfaction professionnelle. L'hypothèse relative à cette problématique était la suivante : Un environnement de travail de qualité, un niveau de formation élevé et l'occupation d'un poste à responsabilité favorisent la satisfaction

professionnelle, et ces facteurs permettent de prédire le niveau de satisfaction.

L'analyse exploratoire met en évidence une corrélation modérée entre l'environnement de travail et la satisfaction professionnelle. Les employés exprimant une satisfaction élevée évaluent leur environnement de travail assez positivement (et inversement). En revanche, les relations entretenues entre JobSatisfaction, JobLevel et TrainingHoursPerYear sont inexistantes. En effet, entre les différents niveaux de responsabilité, la satisfaction semble répartie de manière homogène. De plus, le volume de formation reçu par un individu semble davantage lié à la trajectoire de carrière plutôt qu'au niveau de satisfaction exprimé.

Du côté de la phase de modélisation, les modèles construits se sont avérés faiblement performants lorsqu'il s'agissait de prédire la satisfaction de manière fine (niveaux allant de 1 à 5). Comme pour la variable relative au stress, il a été décidé de binariser JobSatisfaction en vue d'obtenir des performances plus convaincantes. Dans ce cadre, la plupart des modèles développés, et plus spécifiquement la régression logistique, ont affiché des résultats solides.

En menant notre analyse sur les variables discriminantes, une hiérarchie se révèle : la charge de travail, l'environnement de travail et l'équilibre vie privée / vie professionnelle constituent l'essentiel de la prédiction. Ce qui est en adéquation avec les mesures de corrélation obtenues.

Finalement, l'hypothèse est partiellement validée. L'environnement dans lequel un employé évolue constitue bien un levier de la satisfaction, ce qui n'est pas le cas pour le niveau hiérarchique occupé ou encore le volume de formation reçu. La satisfaction peut être relativement bien prédite à condition d'en accepter une représentation simplifiée, représentée sous la forme d'une variable binaire.

Problématique 3 : Caractérisation des groupes d'employés

La troisième et dernière problématique portait sur l'identification de profils types d'employés en ayant recours à des modèles de machine learning non supervisés, et plus précisément de clustering. L'hypothèse formulée à l'égard de cette problématique était la suivante : Les facteurs démographiques exercent une influence secondaire mais significative sur la perception du stress et la satisfaction, et peuvent aider à définir les groupes d'employés lors de l'analyse par clustering.

La segmentation des employés réalisée confirme pleinement cette hypothèse. En effet, le clustering hiérarchique, qui est la méthode de clustering retenue, offre une lecture organisationnelle exploitable. Les groupes formés se caractérisent principalement par l'âge, l'expérience professionnelle, le niveau hiérarchique, le volume de formation reçu au cours d'une année, les responsabilités managériales et le statut marital (dans une moindre mesure).

Les clusters obtenus, au nombre de cinq, vont de jeunes entrants en phase d'intégration aux profils de seniors, voire leaders, ayant davantage de responsabilités. Les variables démographiques et professionnelles sont à l'origine de la segmentation réalisée, ce qui n'est pas le cas pour les variables relatives au bien-être (stress et satisfaction).

L'hypothèse posée est donc pleinement validée. Les facteurs démographiques, bien que ne permettant pas de prédire le bien-être, s'avèrent essentiels à la constitution des profils émanant du clustering réalisé.

Conclusion relative aux problématiques et hypothèses

L'analyse exploratoire et la phase de modélisation informent quant au fait suivant : toutes les variables intuitivement pertinentes ne sont pas nécessairement prédictives. De plus, certaines dimensions, après changement méthodologique deviennent des leviers d'action. Le stress, comme énoncé dans cette partie mais également à plusieurs reprises dans ce rapport, échappe à la modélisation. Concernant la satisfaction, il devient possible de la prédire à condition de la formuler de façon simplifiée. Finalement, la segmentation des forces de travail s'appuie, certes, sur des variables démographiques mais également organisationnelles.

Conclusion

La ligne conductrice de ce travail était d'appliquer une démarche complète de data mining dans le but de mieux appréhender les facteurs influençant le bien-être au travail, c'est-à-dire le stress et la satisfaction. En mettant en place la méthodologie *SEMMA*, il a été possible de structurer l'analyse menée depuis l'exploration des données jusqu'à la construction, l'évaluation et l'interprétation de modèles de machine learning (supervisés et non supervisés).

Au cours de la phase d'exploration des données, il en est ressorti que le jeu de données sur lequel ce travail a été mené était cohérent et de bonne qualité. En effet, peu de transformations lourdes ont dû être réalisées et les données à disposition reflétaient des réalités plausibles. L'analyse univariée, d'une part, a mis en évidence une population professionnellement expérimentée, étant peu stressée et exprimant une satisfaction modérée. L'analyse multivariée, d'autre part, a mis en lumière l'existence de relations fortes, plus spécifiquement entre l'âge, l'expérience, le nombre d'entreprises fréquentées antérieurement et les heures de formation reçues. Toutefois, les habitudes personnelles telles que le temps de sommeil, le volume d'activité physique ou encore la distance domicile-travail se sont avérées plus indépendantes vis-à-vis des autres attributs personnels et organisationnels.

En ce qui concerne les variables cibles, relatives au stress et à la satisfaction, une distinction claire apparaît. Tant sur plan explicatif que prédictif, le stress s'est montré particulièrement difficile à cerner, notamment dû à une indépendance totale par rapport aux autres variables. Il a été conclu que le stress est une dimension complexe qui, très probablement, est expliquée par d'autres facteurs absents du jeu de données utilisé. Au contraire, la satisfaction, elle, s'est avérée bien plus appréhendable au travers de divers leviers que sont l'environnement de travail, la charge de travail et l'équilibre vie privée / vie professionnelle.

Durant l'étape de modélisation, différentes méthodes ont été testées et comparées : arbre de décision, forêt aléatoire, régression logistique et gradient boosting. Les prédictions multi-classes des niveaux de stress et de satisfaction se sont révélées décevantes, probablement liées à une modélisation trop « fine ». Comme réponse, il a été décidé de binariser les variables cibles, permettant ainsi d'obtenir des résultats de prédiction plus satisfaisants et exploitables. Le choix final quant au modèle de référence s'est porté sur la régression logistique, offrant performance prédictive et interprétabilité.

Enfin, les modèles non supervisés, plus précisément de clustering, ont permis d'identifier des groupes d'employés homogènes. Les profils observés vont de jeunes entrants, aux juniors intégrés, aux profils intermédiaires, jusqu'aux individus occupant des postes Senior et Lead. Cette segmentation constitue un apport utile et important pour des départements RH voulant mettre en place des actions ciblées.

En conclusion, ce projet met en évidence à quel point l'application d'une démarche complète de data mining peut être bénéfique dans le secteur des ressources humaines. Des modélisations pertinentes peuvent être menées sur la satisfaction professionnelle, là où le stress s'avère être un phénomène plus complexe à saisir (du moins avec les données à disposition). Comme énoncé dans l'introduction de ce travail, la finalité première est de pouvoir exprimer des recommandations à destination de tout département RH soucieux d'améliorer la satisfaction de ses collaborateurs au travail. Dans ce sens, en voici quelques-unes dans le paragraphe qui suit.

Les résultats obtenus soulignent le rôle central que jouent l'environnement de travail, la charge de travail et l'équilibre vie privée / vie professionnelle dans la satisfaction des employés, appelant à améliorer les conditions de travail, clarifier les attentes et renforcer les politiques de flexibilité. Les difficultés rencontrées lors de la prédiction du stress informent quant à la complexité de cette dimension. Il est nécessaire de compléter les approches quantitatives par des outils qualitatifs. Cela peut prendre la forme d'enquêtes en interne ou encore de dispositifs de feedback. Enfin, la segmentation réalisée constitue une étape clé, offrant aux départements RH l'opportunité de construire des politiques ciblées en fonction des profils identifiés.

Conclusion sur l'exercice

Ce projet de data mining a été l'occasion de mettre en application de manière concrète et approfondie les divers concepts abordés dans le cadre du cours théorique. Par le biais d'un jeu de données, plusieurs problématiques et hypothèses ont été formulées concernant les variables que sont la satisfaction et le stress. Pour y répondre et évaluer la validité de ces hypothèses, la méthodologie *SEMMA* a été mobilisée, guidant ainsi l'ensemble de la démarche analytique, depuis la phase d'exploration des données jusqu'à l'interprétation des résultats. L'application rigoureuse de ce processus a fourni un cadre clair pour la réalisation du projet, soulignant l'importance de chaque étape dans sa réussite.

Au-delà des conclusions tirées, ce projet a démontré à quel point l'exploration et la transformation des données sont essentielles pour garantir la pertinence des modèles mobilisés. Les tentatives d'explication et de prédiction du stress se sont avérées vaines, mettant en avant les limites de n'importe quel jeu de données (et notamment de celui mobilisé). Certains phénomènes peuvent se révéler complexes à appréhender et dépendent souvent de facteurs n'étant pas toujours à disposition (pression psychologique, éléments personnels, qualité du management, ...).

Cet exercice a également permis de se familiariser avec des outils et techniques de machine learning divers et variés. L'analyse comparative des performances des modèles construits a souligné la nécessité de pouvoir, dans certains cas, adapter la stratégie de modélisation mise en place (passage d'une approche multi-classes à une approche binaire). Cela illustre l'importance de l'esprit critique et de l'adaptation méthodologique, notamment face à des résultats insatisfaisants. Cette démarche illustre une réalité : l'obtention de la meilleure solution passe souvent par des ajustements itératifs.

En outre, ce projet a été formateur sur le plan académique et rédactionnel. Il a permis de renforcer nos capacités à pouvoir communiquer de manière quantitative et qualitative des analyses complexes relatives à des problématiques et hypothèses formulées. De plus, ce travail, de par son ampleur et son exigence, a représenté un véritable défi. Être capable de réaliser une démarche complète de data mining a demandé organisation, répartition efficace des tâches et étroite collaboration.

En conclusion, à travers ce projet, il a été possible de consolider les acquis théoriques vus durant le cours de Data Mining. Il illustre l'intérêt de la mobilisation de méthodes de fouille de données, mais également les limites qu'elles présentent dans l'apport de réponses à des problématiques concrètes. Il n'y a guère de doutes quant au fait que cet exercice constitue un enrichissement solide, tant sur le plan académique que professionnel.