

Comprendre le bien-être au travail :

analyse des déterminants et de leurs impacts, prédiction et clustering RH

Projet Data Mining (Méthodologie SEMMA) | Lenny Andry & Arthur Ottevaere

PROBLÉMATIQUES

1. Stress au travail : Quels sont les facteurs principaux, parmi ceux identifiés, qui expliquent le stress ressenti par un employé, et permettent de prédire son niveau de stress ?

2.Satisfaction professionnelle : Quels sont les déterminants expliquant la satisfaction professionnelle des employés, et permettant de prédire leur niveau de satisfaction ?

3.Caractérisation des groupes d'employés : Comment peut-on regrouper les employés en clusters homogènes afin d'identifier des profils types et d'aider le personnel RH dans ses décisions managériales ?

Hypothèses de travail

Variable	Impact
Charge de travail	↑ Stress
Activité physique (en heures)	↓ Stress
Temps de sommeil (en heures)	↓ Stress
Equilibre vie privée/professionnel	↓ Stress
Environnement de travail	↑ Satisfaction
Formations par an (en heures)	↑ Satisfaction
Statut hiérarchique	↑ Satisfaction

SAMPLE

Le jeu de données **"Employee Survey"** a été extrait de **Kaggle**, l'une des principales plateformes de science des données et d'apprentissage automatique. Il contient **3025 observations**, chacune représentant les caractéristiques propres à un employé identifié par un ID unique.

Jeu de données

"Employee Survey"

Nbr. d'observations

3.025

Nbr. de variables

23

Train Set

80 %

Test Set

20 %

EXPLORE

Analyse univariée



Profil type de l'employé :

- Age moyen : 35.7 ans
- Genre : Majorité masculine (50.5%)
- Secteurs dominants : IT (25.6%) et Finance (21%)
- Ancienneté : Profils majoritairement Seniors (35.3%)

Santé et bien-être :

- Sommeil : 7h/nuit en moyenne
- Stress : Niveau moyen déclaré faible (1.74/5)
- Satisfaction : Niveau moyen modéré (3.39/5)

Analyse multivariée



Axe "Carrière" : Des relations fortes sont constatées entre les variables relatives à l'âge, l'expérience, le nombre d'entrées fréquentées antérieurement, la taille des équipes, le nombre de subordonnés et le volume annuel de formation.



Axe "Satisfaction" : La satisfaction est positivement corrélée à la qualité de l'Environnement de travail (WorkEnv) et à l'Équilibre vie pro/perso (WLB). Elle est cependant inversement impactée par une Charge de Travail trop élevée.



Axe "Stress" : Le stress présente une indépendance quasi totale vis-à-vis des autres variables organisationnelles et personnelles, suggérant des causes externes non capturées dans le dataset.

MODEL & ASSESSMENT

Modèles supervisés

Arbre de décisions

Forêt aléatoire

Régression logistique

Gradient Boosting

Durant la modélisation, plusieurs méthodes ont été testées (arbre de décision, forêt aléatoire, régression logistique, gradient boosting). Les prédictions multi-classes étant peu concluantes, **les variables cibles ont été binarisées**, améliorant la qualité des résultats. Le modèle retenu est la régression logistique, alliant performance et interprétabilité (comme affiché ci-dessous).

Satisfaction

Modèles	AUC	Accuracy	F1-score	MCC
Logistic Regression	0.779	0.74	0.737	0.464
Random Forest	0.778	0.726	0.714	0.435
Tree	0.659	0.648	0.638	0.265
Gradient Boosting	0.781	0.739	0.732	0.461


Stress

Modèles	AUC	Accuracy	F1-score	MCC
Logistic Regression	0.613	0.785	0.712	0.057
Random Forest	0.611	0.783	0.618	-0.03
Tree	0.526	0.755	0.668	0.009
Gradient Boosting	0.595	0.788	0.742	0.103

Les résultats pour la variable Stress binarisée restent inférieurs à ceux de la satisfaction. Malgré l'amélioration générale des métriques, **le MCC se dégrade fortement**, atteignant **-0.030** avec la forêt aléatoire, tandis que la satisfaction voit ses performances doubler par rapport à la situation où les variables sont ordinales.

Modèles non supervisés

① Score de silhouette de **0.5614** - Partitionnement de qualité satisfaisante. En effet, une valeur supérieure à 0.5 garantit des clusters avec une structure suffisamment interprétable.



Clustering effectué sur base d'un clustering hiérarchique

- **C1 - Leaders expérimentés :** Employés âgés et expérimentés, postes de niveau Senior et Lead, grandes équipes, plusieurs collaborateurs, forte formation (54-64 h), éducation supérieure au secondaire.
- **C2 - Groupe hétérogène :** Profils très diversifiés (âge, expérience, hiérarchie), équipes et responsabilités variées, formation importante (39-64 h), peu homogène.
- **C3 - Professionnels en consolidation :** Niveau Mid, expérience intermédiaire, équipes modérées, peu de responsabilités, formation moyenne (30-40 h), éducation supérieure au secondaire.
- **C4 - Débutants / Interns :** Jeunes, sans expérience ni responsabilités, intégrés dans grandes équipes, célibataires, formation faible (~10 h).
- **C5 - Juniors en développement :** Jeunes, expérience limitée, petites équipes, responsabilités faibles, formation modérée (20-23 h), statut marital diversifié.

CONCLUSION

Constat

- **Satisfaction :** Elle dépend surtout de l'environnement de travail, de la charge de travail et de l'équilibre vie privée/professionnelle, tandis que le niveau hiérarchique et la formation ont peu d'impact ; l'hypothèse est donc seulement partiellement validée.
- **Stress :** Les analyses montrent que les variables étudiées n'expliquent pas le stress : l'hypothèse est réfutée et le stress dépend probablement d'autres facteurs non présents dans les données.
- **Segmentation :** Le clustering révèle que les profils d'employés sont essentiellement définis par des variables démographiques et professionnelles (âge, expérience, niveau hiérarchique, formation, responsabilités), tandis que le stress et la satisfaction n'influencent pas la segmentation ; l'hypothèse est ainsi pleinement validée.

VS

Action

- **Satisfaction :** Le rôle central que jouent l'environnement de travail, la charge de travail et l'équilibre vie privée / vie professionnelle dans la satisfaction des employés, appelle à améliorer les conditions de travail, clarifier les attentes et renforcer les politiques de flexibilité.
- **Stress :** Les difficultés rencontrées lors de la prédiction du stress informent quant à la complexité de cette dimension. Il est nécessaire de compléter les approches quantitatives par des outils qualitatifs.
- **Segmentation :** La segmentation réalisée constitue une étape clé, offrant aux départements RH l'opportunité de construire des politiques ciblées en fonction des profils identifiés.