

Data Mining – Fouille de Données

Annexe Technique : Scripts et Codes

Réalisé dans le cadre du cours de Data Mining



UCLouvain

Encadrant :

A. AIT EL CADI

Étudiants :

Lenny Andry

Arthur Ottevaere

Date de remise : 15 janvier 2026

Table des matières

Introduction	1
Explore	2
Analyse univariée	2
Variables ordinales	3
Variables nominales	4
Variables continues	5
Variables cibles	7
Analyse multivariée	8
Matrice de corrélation de Spearman	8
Matrice de corrélation de Pearson	10
Matrices de contingence	12

Introduction

Cette annexe technique constitue le prolongement méthodologique et informatique du rapport principal, traitant des différents facteurs d'influence de la satisfaction et du stress au travail.

Alors que l'essentiel de la modélisation prédictive a été réalisé sous l'environnement *Orange Data Mining*, la finesse de certaines analyses statistiques et la production de visualisations avancées ont nécessité le recours aux langages de programmation R (via RStudio) et Python (via les bibliothèques *pandas*, *seaborn* et *matplotlib*).

Ce document poursuit trois objectifs fondamentaux :

1. **Transparence** : Exposer les scripts sources ayant permis la génération des matrices de corrélation, des distributions de variables et des tableaux de contingence.
2. **Reproductibilité** : Permettre à tout lecteur de répliquer l'intégralité des traitements statistiques et des graphiques présentés dans le corps du rapport principal.
3. **Rigueur scientifique** : Démontrer la robustesse de notre démarche en fournissant les détails de l'implémentation technique.

Fidèle à la structure du projet, cette annexe suit rigoureusement le fil conducteur de la méthode *SEMMA*, permettant ainsi de faire le lien direct entre les lignes de code présentées ici et les résultats analysés dans le travail principal. Cependant, la phase "Explore" est l'unique phase qui présente des illustrations visuelles constituées avec un outil/programme tiers. Par conséquent, la phase d'exploration sera la seule présente dans ce rapport annexe.

Explore

Dans le cadre de l'exploration du jeu de données, plusieurs représentations visuelles ont été réalisées, notamment pour les analyses univariées et multivariées.

Analyse univariée

TABLE 3 – Statistiques Descriptives des Données (N = 3025)

Catégorie	Variable	Statistiques Clés
<i>Attributs personnels</i>	Age	Moyenne : 35.7 ans ($\sigma = 10.2$), Médiane : 34 ans
	Gender	Hommes (50.5%), Femmes (41.0%), Autre (8.5%)
	EduLevel	Bachelor (76.0%), Master (12.6%), Secondaire (8.1%)
	MaritalStatus	Célibataires (47.5%), Mariés (46.2%), Divorcés (6.2%)
	SleepHours	Moyenne : 7.0 h (Min : 4.0 h)
<i>Attributs professionnels</i>	PhysicalActivityHours	Moyenne : 2.0 h (Médiane : 2.0 h)
	Dept	IT (25.6%), Finance (21.1%), Opérations (15.0%)
	JobLevel	Senior (35.3%), Intermédiaire (25.3%), Junior (19.9%)
	Experience	Moyenne : 9.1 ans (Max : 29 ans)
	EmpType	Temps Plein (68.7%), Partiel (21.2%), Autre (10.2%)
	haveOT	30.9% effectuent des heures supplémentaires
	TeamSize	Moyenne : 16.52 personnes (Min : 5 & Max : 30)
	TrainingHoursPerYear	Moyenne : 37.3 h/an
	NumReports	Moyenne : 2.38
	NumCompanies	Moyenne : 4.25 (Max : 12)
<i>Attributs organisationnels & environnementaux</i>	CommuteDistance	Moyenne : 13.5 km
	CommuteMode	Voiture (35.9%), Transports (29.6%), Vélo (14.4%)
	WLB (1-5)	Moyenne : 3.06 ($\sigma = 1.45$)
	WorkLoad (1-5)	Moyenne : 2.97 ($\sigma = 1.40$)
	WorkEnv (1-5)	Moyenne : 3.03
<i>Indicateurs</i>	JobSatisfaction (1-5)	Moyenne : 3.39 ($\sigma = 1.26$)
	Stress (1-5)	Moyenne : 1.74 ($\sigma = 1.06$)

Table 3 – Statistiques Descriptives des Données (N = 3025) - RStudio

```
# --- Installation des packages ---
install.packages("xtable")
library(xtable)

# --- Chargement des données ---
df_employe <- read.csv("employee_survey.csv")

# --- Script R pour les Statistiques Descriptives ---
print(summary(df_employe))
```

Variables ordinales




FIGURE 1 – Distributions variables ordinales

Figure 1 – Distributions variables ordinales - RStudio

```
# --- Installation des packages ---
install.packages("xtable")
library(xtable)

# --- Chargement des données ---
df_employe <- read.csv("employee_survey.csv")

# --- Script R : Distribution - Scores de Perception (3 Variables) ---
variables <- c("WLB", "WorkEnv", "Workload")
par(mfrow=c(1, 3), mar=c(4, 4, 3, 1))

for (col_name in variables) {
  counts <- table(factor(df_employe[[col_name]], levels=1:5))

  # Génération du graphique
  barplot(counts,
    main=paste("Distribution de", col_name),
    xlab="Score (1-5)",
    ylab="Effectif",
    col="skyblue")
}
par(mfrow=c(1, 1))
```

Variables nominales




FIGURE 2 – Distributions variables nominales

Figure 2 – Distributions variables nominales - RStudio

```
# --- Installation des packages ---
install.packages("xtable")
library(xtable)

# --- Chargement des données ---
df_employe <- read.csv("employee_survey.csv")

# --- Script R : Distribution des Variables Nominales ---
variables_bis <- c("Dept", "JobLevel", "MaritalStatus", "EmpType",
                  "CommuteMode", "EduLevel", "haveOT")
par(mfrow=c(2, 4), mar=c(8, 4, 2, 1))

for (col_name in variables_bis) {
  counts <- table(df_employe[[col_name]])

  # Génération du graphique
  barplot(counts,
          main=col_name,
          ylab="Effectif",
          col="skyblue",
          las=2, # Rotation des labels X
          cex.names=0.7) # Taille des labels X réduite
}
par(mfrow=c(1, 1))
```

Variables continues




FIGURE 3 – Boxplots variables continues

Figure 3 – Boxplots variables continues - RStudio

```
# --- Installation des packages ---
install.packages("xtable")
library(xtable)

# --- Chargement des données ---
df_employe <- read.csv("employee_survey.csv")

# --- Script R - Boxplots des variables continues ---
par(mfrow=c(1, 3), mar=c(6, 4, 4, 1))

# --- GRAPHE 1 : Distance & Expérience ---
boxplot(df_employe$CommuteDistance, df_employe$Experience,
        names=c("CommuteDistance", "Experience"),
        main="CommuteDistance & Experience",
        col=c("skyblue", "skyblue"),
        ylab="Valeur")

# --- GRAPHE 2 : Âge & Heures de Formation ---
boxplot(df_employe$Age, df_employe$TrainingHoursPerYear,
        names=c("Age", "TrainingHoursPerYear"),
        main="Age & TrainingHoursPerYear",
        col=c("skyblue", "skyblue"),
        ylab="Valeur")

# --- GRAPHE 3 : Sommeil & Activité Physique ---
boxplot(df_employe$SleepHours, df_employe$PhysicalActivityHours,
        names=c("SleepHours", "PhysicalActivityHours"),
        main="SleepHours & PhysicalActivityHours",
        col=c("skyblue", "skyblue"),
        ylab="Valeur")

par(mfrow=c(1, 1))
```


Variables cibles




FIGURE 4 – Distributions variables cibles

Figure 4 – Distributions variables cibles - RStudio

```
# --- Installation des packages ---
install.packages("xtable")
library(xtable)

# --- Chargement des données ---
df_employe <- read.csv("employee_survey.csv")

# --- Script R - Distributions de JobSatisfaction et Stress
par(mfrow=c(1,2))

hist(df$JobSatisfaction,
     main="Distribution de JobSatisfaction",
     xlab="Note (1 à 5)",
     col="skyblue",
     border="white",
     breaks=seq(1, 6, 1),
     right=FALSE)

hist(df$Stress,
     main="Distribution du Stress",
     xlab="Note (1 à 5)",
     col="skyblue",
     border="white",
     breaks=seq(1, 6, 1),
     right=FALSE)
```

Analyse multivariée

Matrice de corrélation de Spearman




FIGURE 5 – Matrice de corrélation de Spearman

Figure 5 – Matrice de corrélation de Spearman - Python

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Charger le fichier CSV (chemin complet)
df = pd.read_csv("employee_survey (initial).csv")

# Sélection des variables quantitatives
quant_vars = [
    'Age', 'Experience', 'WLB', 'WorkEnv',
    'PhysicalActivityHours', 'Workload', 'Stress', 'SleepHours',
    'CommuteDistance', 'NumCompanies', 'TeamSize', 'NumReports',
    'TrainingHoursPerYear', 'JobSatisfaction'
]

# Calcul de la matrice de corrélation
corr_matrix = df[quant_vars].corr(method='spearman')

# Heatmap avec trois chiffres après la virgule
plt.figure(figsize=(12,10))
sns.heatmap(corr_matrix, annot=True, fmt=".3f", cmap="coolwarm", cbar=True)
plt.title("Matrice de corrélation Spearman")

# Ajuster la mise en page pour éviter que quelque chose soit coupé
plt.tight_layout()

plt.show()
```

Matrice de corrélation de Pearson




FIGURE 6 – Matrice de corrélation de Pearson

Figure 6 – Matrice de corrélation de Pearson - Python

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Charger le fichier CSV
df = pd.read_csv("employee_survey (initial).csv")

# Sélection des variables continues pour Pearson
quant_vars = [
    'Age', 'Experience', 'PhysicalActivityHours', 'SleepHours',
    'CommuteDistance', 'TrainingHoursPerYear'
]

# Calcul de la matrice de corrélation
corr_matrix = df[quant_vars].corr(method='pearson')

# Heatmap avec trois chiffres après la virgule
plt.figure(figsize=(12,10))
sns.heatmap(
    corr_matrix,
    annot=True,
    fmt=".3f",
    cmap="coolwarm",
    cbar=True,
    annot_kws={"size":10}, # taille des annotations
)
plt.title("Matrice de corrélation Pearson", fontsize=16)

# Ajuster la mise en page et rotation des labels pour éviter le chevauchement
plt.xticks(rotation=45, ha='right')
plt.yticks(rotation=0)
plt.tight_layout()
plt.show()
```

Matrices de contingence

La matrice et le code illustrés ci-dessous représentent un exemple de sortie. En effet, il est possible d'obtenir, en changeant le nom des variables dans le code R, n'importe quelle matrice de contingence. La contingence entre les variables Stress et Dept est reprise dans l'exemple illustratif ci-dessous.

Stress	Dept								Total
	Cust.	Fin.	HR	IT	Legal	Marketing	Op.	Sales	
1	5.1	19.8	4.6	26.4	8.8	10.6	15.8	9.0	100.0
2	3.9	22.4	5.2	26.2	9.0	9.5	12.7	11.0	100.0
3	5.9	22.3	4.2	23.2	9.2	10.8	15.0	9.4	100.0
4	2.8	24.6	6.1	23.5	10.1	9.5	17.3	6.1	100.0
5	5.3	25.0	3.9	21.1	10.5	14.5	9.2	10.5	100.0

TABLE 4 – Matrice de contingence entre Stress et Dept (en %)

Table 4 - 11 : Matrices de contingence - RStudio

```
# --- Installation des packages ---
install.packages("xtable")
library(xtable)

# --- Chargement des données ---
df_employe <- read.csv("employee_survey.csv")

# --- Script R - Matrices de contingence ---
tableau_counts <- table(df$Stress, df$Dept) #Variable à modifier en fonction de
→ la matrice que l'on veut afficher !
tableau_pct <- prop.table(tableau_counts, margin = 1) * 100
tableau_final <- addmargins(tableau_pct, margin = 2)

print(round(tableau_final, 1))
```