

MLSMM2153 : Web Mining

Sujet 4 : Analyse des critiques culturelles sur des blogs cinéma

Réalisé dans le cadre du cours de Web Mining



UCLouvain

Encadrants :

Sylvain Courtain

Corentin Vande Kerckhove

Étudiants :

Lenny Andry

Mohamed El Mohcine

Arthur Ottevaere

Date de remise : 6 janvier 2026

Ci-après figure le lien du dépôt GitHub reprenant l'ensemble du code développé ainsi que les ressources essentielles à la reproduction des analyses menées :

<https://github.com/ArthurOttevaere/WebMining-Cinema-Reviews>

Table des matières

Introduction	1
Collecte de données (Scraping)	1
Sélection des sources	1
Stratégie de navigation et d'exploration	2
Extraction et structuration des données	2
Qualité et limites du corpus	3
Text Mining	3
Présentation du corpus	4
Prétraitement linguistique du corpus	4
Représentation vectorielle et similarité	5
Réduction SVD et normalisation	5
Analyse de similarité	5
Analyse descriptive	6
Fréquence lexicale : unigrams et bigrams récurrents	6
Richesse lexicale : Type-Token Ratio (TTR)	6
Analyse sémantique	7
Vocabulaire évaluatif : mots porteurs de jugement	7
Etude des relations : polarité globale, ratio positif/négatif et score	7
Structure narrative : trajectoire de sentiment	8
Groupement des documents	8
Détermination du nombre de clusters K	8
Analyse croisée	9
Link analysis	9
Methodologie	10
Analyse du réseau	10
Mesures de centralité, de prestige et d'influence	11
Topologie inter-cluster	12
Conclusion	12
Annexes	13

Introduction

Dans le cadre du cours de *Web Mining*, ce projet repose sur une analyse approfondie de critiques culturelles issues du web, faisant appel à diverses techniques de *Scraping*, de *Text Mining* et de *Link Analysis*. Relatif au *Sujet 4*, ce travail se focalise sur l'étude de critiques présentes sur des blogs spécialisés, et plus spécifiquement dans le domaine cinématographique. La collecte de données se concentre exclusivement sur l'un des blogs critiques les plus réputés à l'échelle internationale : *RogerEbert.com*. Ce choix a été opéré en raison de la qualité rédactionnelle des reviews, de la richesse du vocabulaire évaluatif et de la structure éditoriale cohérente du site.

Outre la collecte de textes, ce projet a pour but d'explorer la manière dont les œuvres culturelles sont valorisées, caractérisées et connectées au sein d'un corpus structuré. Plus précisément, cette étude s'articule autour des trois objectifs complémentaires : (1) la collecte et l'organisation des données, à travers la définition d'une stratégie de collecte automatisée et contrôlée permettant la constitution d'un corpus cohérent et qualitatif ; (2) le *Text Mining*, visant à analyser le contenu textuel des reviews afin de repérer des motifs lexicaux et stylistiques, d'examiner la distribution des notes attribuées aux films ainsi que la polarité et les dynamiques sémantiques relatives aux évaluations ; (3) la *Link Analysis*, qui modélise les liens entre critiques sous forme d'un réseau basé sur leurs proximités sémantiques, afin de révéler les regroupements thématiques ainsi que les œuvres occupant une position centrale ou charnière au sein du corpus.

La problématique centrale de ce rapport porte sur la manière dont les critiques de films publiées sur le blog de *Roger Ebert* forment l'appréciation des œuvres et influencent la notation des films. Il s'agit notamment d'examiner si le contenu des critiques est en alignement avec la note attribuée, tout en identifiant les relations thématiques émergentes entre les reviews analysées. En intégrant extraction automatisée, analyse linguistique et modélisation relationnelle, ce projet cherche à révéler les dynamiques organisant les critiques de films, mais aussi à démontrer l'intérêt de la mobilisation de méthodes de *Web Mining*.

Collecte de données (Scraping)

Sélection des sources

La première étape du projet consiste en l'obtention d'un corpus de critiques cinématographiques solide et bien organisé. Le volume de pages web à récupérer étant important, la mobilisation d'un outil d'extraction automatisée s'est révélée indispensable afin de garantir une collecte efficace. Afin de répondre à la problématique relative à la manière dont les critiques expriment leur avis sur les films, il nous a semblé naturel de sélectionner le site <https://www.rogerebert.com> comme source principale de données. Ce choix a notamment été motivé par la présence de nombreuses caractéristiques essentielles :

- **Pertinence et fiabilité** : Ce site est une référence dans le monde des critiques cinématographiques. Contrairement à des plateformes telles que IMDb, il recense des textes longs, écrits par des auteurs professionnels, offrant une richesse lexicale primordiale à la réalisation d'analyses plus fines et robustes.
- **Cohérence avec le sujet** : Le site est structurellement dédié à la critique, réduisant drastiquement le risque de collecter des pages hors sujet (commentaires, avis, forums).
- **Choix de la langue** : Conformément aux recommandations méthodologiques du projet, l'anglais a été retenu comme langue de référence pour le corpus. Ce choix permet d'accéder à un plus grand volume d'informations et de simplifier les traitements ultérieurs liés aux données collectées (encodages et bibliothèques NLP).

Stratégie de navigation et d'exploration

Dans le but de constituer un corpus représentatif sans tomber dans le piège de la collecte massive et non contrôlée, c'est la méthode *Breadth-First Search* (BFS) qui a été retenue. Cette approche permet ainsi de limiter la couverture de collecte en procédant « niveau par niveau ». Le BFS, aussi appelé recherche en largeur, utilise des *Seeds* comme point d'entrée. Le script interroge le flux *AJAX* du site afin de récupérer une liste de critiques récentes qui serviront de graines pour la suite de la collecte. Une fois cette première itération réalisée, le script va, pour chaque critique visitée, analyser le contenu textuel de celle-ci à la recherche d'hyperliens menant vers d'autres critiques. Ces nouvelles URL sont ensuite ajoutées à une file d'attente (*Queue*). Cette méthode est essentielle afin d'assurer une cohérence sémantique. En effet, les critiques ne sont pas collectées au hasard mais via l'exploration de leurs citations internes, favorisant l'émergence naturelle de communautés utiles pour l'analyse de liens. De plus, une contrainte de profondeur ($depth < 2$) limite l'exploration aux voisins immédiats et secondaires, garantissant un corpus centré sur les citations directes sans divergence exponentielle.

Afin de consolider l'extraction d'informations utiles à notre sujet d'étude, divers paramètres (filtres) ont été appliqués. Seules les URL contenant le motif `/reviews/` et appartenant au domaine `https://www.rogerebert.com` ont été retenues parmi l'ensemble des liens présents sur chaque page de critique, ce qui a permis de réduire considérablement le bruit dans les données collectées.

Extraction et structuration des données

Une fois la page d'une critique identifiée, le script procède à l'analyse de la page HTML (parsing) via la bibliothèque *BeautifulSoup*. Pour chaque critique, voici les champs extraits :

TABLE 1 – Extraction et structuration des données collectées

Champ	Description (Source HTML)	Usage prévu
Titre du film	Extrait de la balise <h1>.	Identification unique des nœuds (Graphe).
Score	Récupéré via les classes CSS des étoiles (ex : <code>star-box</code>).	Analyse des relations avec d'autres métriques (Sentiment vs Note).
Texte complet	Contenu des balises <p> de la <div> principale.	Text Mining, TF-IDF, Clustering.
Métadonnées	Année, Réalisateur, Acteurs principaux, Durée, Genre, Auteur, Date de parution.	Enrichissement de l'analyse.
URL Parent	L'URL de la page précédente (source du lien).	Reconstruction des arêtes du graphe (Link Analysis).

Les données brutes ont ensuite été sauvegardées et figées dans un fichier au format `.csv` sous le nom de `reviews_final_900.csv`. La suite des analyses se fera sur ce corpus afin de garantir la persistance et la réutilisabilité entre les différentes étapes, du *Text Mining* à l'analyse de liens.

Qualité et limites du corpus

Bien que le processus soit automatisé, plusieurs limites ont été identifiées lors de la collecte d'informations. Initialement, le texte des critiques contenait du bruit (publicités, vidéos). Un pré-nettoyage a donc été intégré au script afin de supprimer les segments HTML indésirables pour le stockage des données.

Bien que qualitatif, le corpus des critiques issues du site *Roger Ebert* présente un biais méthodologique qu'il convient d'identifier lors de l'évaluation de la qualité des données. Malgré la pluralité des rédacteurs, une homogénéité sémantique dans le style des critiques pourrait apparaître. Cette similarité stylistique est susceptible d'influencer l'analyse sémantique et les résultats du clustering prévus dans la suite du pipeline.

La phase de collecte s'achève sur un scraping de 900 critiques, structurées et figées dans leur format `.csv`. Le moment est donc venu de franchir le seuil de l'analyse sémantique pour transformer ces milliers de mots bruts en un résultat vivant et visuel des thèmes et sentiments qui animent les critiques cinématographiques du site *Roger Ebert*.

Text Mining

Disposant désormais d'un corpus structuré de 900 critiques, cette phase du projet vise à convertir le contenu textuel brut en indicateurs quantitatifs exploitables. L'objectif est double : qualifier statistiquement le jeu de données et révéler les structures sémantiques latentes via des techniques de traitement du langage naturel (NLP).

Présentation du corpus

L'analyse quantitative révèle une longueur moyenne de 933 mots par critique, confirmant la densité informationnelle du dataset. Contrairement aux commentaires standards, ces essais critiques argumentés offrent une matière sémantique riche. La distribution des scores (Annexe 1) met en évidence un déséquilibre marqué : les notes supérieures à 3 étoiles dominent le corpus (73.1 %), tandis que les critiques très négatives restent marginales (< 7 %). Cette asymétrie traduit un biais de positivité éditoriale : la tendance à privilégier les œuvres qui « méritent d'être vues » entraîne une surreprésentation des notes favorables.

L'analyse des boxplots (Annexe 2) mettant en relation les deux dimensions discutées précédemment (longueur des critiques et scores) met en évidence une tendance globale croissante : la médiane du nombre de mots augmente progressivement avec le score. Les critiques associées aux notes élevées présentent non seulement des médianes plus importantes, mais également une dispersion accrue. Cette variabilité est particulièrement marquée pour les films notés 4/4, catégorie qui concentre les critiques les plus longues ainsi que les valeurs extrêmes les plus élevées, traduisant un engagement rédactionnel plus soutenu pour les œuvres les mieux évaluées.

Prétraitement linguistique du corpus

Prétraitement, tokenisation et nettoyage : Le nettoyage HTML effectué lors du scraping n'étant pas suffisant pour une analyse linguistique, un pipeline de prétraitement spécifique a été implémenté via la bibliothèque NLTK. Une normalisation stricte a été appliquée pour éliminer le bruit résiduel. L'utilisation d'expressions régulières (Regex) a permis de supprimer les caractères non alphabétiques et d'harmoniser la casse. Cette étape est indispensable pour éviter la duplication lexicale, qui consisterait à traiter « Movie » et « movie » comme deux termes distincts.

Tokenisation et POS Tagging : La tokenisation a été suivie d'un étiquetage grammatical (POS Tagging). Cette annotation joue un rôle pivot dans le pipeline : au-delà de la qualification des termes, elle conditionne la réduction de dimensionnalité en permettant d'isoler les verbes et d'identifier les entités nommées vouées à être exclues.

Stratégie de lemmatisation : Contrairement au stemming qui tronque brutalement les mots, une lemmatisation conditionnelle via *WordNet* a été privilégiée pour assurer une normalisation respectueuse du sens. Une distinction technique applique le paramètre `wordnet.VERB` strictement aux verbes afin de normaliser les actions vers leur infinitif. Les autres catégories, dont les adjectifs, subissent une lemmatisation par défaut. Ce choix évite la réduction systématique des comparatifs, préservant ainsi les nuances d'intensité essentielles au ton critique. Enfin, le filtrage élimine stopwords et noms propres pour ne retenir que la substance thématique.

Réduction et filtrage du vocabulaire : Comme le soulignent Grimmer et Stewart (2013), la fixation des seuils ne repose pas sur une règle universelle mais doit être contingente aux spécificités

du corpus (taille, diversité lexicale, ...). Deux filtres statistiques ont donc été appliqués :

- **Seuil inférieur (`min_df` = 2)** : élimination des hapax et fautes de frappe (bruit sans valeur prédictive).
- **Seuil supérieur (`max_df` = 0.5)** : exclusion des termes omniprésents (> 50 %, ex. « film »), considérés comme du bruit contextuel.

Ce filtrage a réduit le corpus de 839 744 à 307 367 tokens (-63 %). Le dictionnaire final de 34 297 termes uniques transforme ainsi un vocabulaire brut massif en une représentation compacte et mieux informée, optimisant le ratio signal/bruit.

Représentation vectorielle et similarité

La projection des données dans un espace vectoriel permet le calcul de similarités géométriques. La méthode TF-IDF (intégrant unigrams et bigrams) a été retenue : contrairement au *Bag of Words*, elle pondère les termes pour valoriser le vocabulaire spécifique au détriment du générique. Bien que l'état de l'art (BERT, Doc2Vec) capte mieux la sémantique complexe, ces modèles opèrent souvent comme des « boîtes noires ». Dans cette analyse exploratoire, le TF-IDF a été privilégié pour son explicabilité directe, permettant d'identifier précisément quels termes fondent le rapprochement vectoriel entre deux critiques.

Réduction SVD et normalisation

Une réduction dimensionnelle via Truncated SVD (150 composantes) a été appliquée pour condenser l'information sémantique. Le choix de 150 composantes garantit la capture de l'essentiel : une dimension trop faible causerait une perte de structure latente (sous-apprentissage), tandis qu'un nombre trop élevé intégrerait du bruit de faible variance (sur-apprentissage). Cette étape précède une normalisation L2. La projection sur une sphère unitaire est fondamentale mathématiquement : sur vecteurs normalisés, minimiser la distance euclidienne équivaut à maximiser la similarité cosinus. Cela garantit que la longueur variable des textes n'influence pas artificiellement le calcul de proximité.

Analyse de similarité

Sur base du tableau (Annexe 3) présentant les paires de critiques ayant un score de similarité cosinus supérieur à 0.7, divers résultats valident la cohérence de l'approche utilisée :

- **Identité thématique** : La paire *A Bug's Life* / *Antz* obtient le score maximal (0.945). Bien que ce soient deux films distincts, ils traitent du même sujet (les fourmis) et sont sortis à la même période, partageant donc un champ lexical quasi identique.
- **Continuité de genre** : La proximité entre *Queen of the Damned* et *Nosferatu* (0.858) démontre la capacité du modèle à relier des œuvres par leur champ lexical (vampirisme) malgré l'écart temporel.

- **Nœud pivot** : Le film *Dog Day Afternoon* apparaît à trois reprises. Il agit comme un *hub* sémantique, son profil lexical (mots-clés du suspense et du drame) partageant de fortes similarités avec des œuvres variées du corpus.

Analyse descriptive

A la suite de la représentation vectorielle des documents par TF-IDF et de l'analyse de similarité, cette section cherche à décrire le corpus d'un point de vue lexical et stylistique, permettant ainsi de mieux appréhender la manière dont les critiques forment leurs avis sur les œuvres. L'analyse descriptive menée permet d'identifier les régularités linguistiques des évaluations présentes au sein du site *Roger Ebert*.

Fréquence lexicale : unigrams et bigrams récurrents

L'analyse des tokens les plus fréquents (ceux obtenus après les étapes de prétraitement, tokenisation, réduction et filtrage) met en lumière un vocabulaire qui va bien au-delà d'une simple représentation factuelle des œuvres. En effet, des mots tels que *woman*, *world*, *love*, ou encore *best* figurent parmi les plus courants (Annexes 4 et 5). Cette coexistence entre notions relatives à la narration (*woman*, *world*) et à l'émotion (*love*, *best*) montre que les critiques formulées adoptent une posture d'interprétation et d'évaluation. D'autres termes, plus génériques, comme *something*, *another* et *still* participent à la construction d'un jugement nuancé et progressif. Sur base de ce premier constat, il est possible d'avancer que les motivations éditoriales du site *Roger Ebert* sont davantage tournées vers une analyse qualitative plutôt que sur des verdicts tranchés.

L'étude des bigrams les plus fréquents (Annexe 6) permet de préciser cette observation en mettant en évidence des expressions lexicales caractéristiques de discours critiques. Des termes comme *special effect*, *writer director* ou *best friend* montrent que les critiques se concentrent sur des éléments plus techniques (direction, effets visuels), mais également sur les relations pouvant exister entre personnages. D'autres bigrams tels que *high school* ou *comic book* révèlent que le corpus s'articule autour de certains univers culturels. Cela souligne la tendance des critiques à préciser les cadres narratifs dans lesquels les œuvres s'inscrivent.

Richesse lexicale : Type-Token Ratio (TTR)

Afin d'évaluer la diversité lexicale et le degré d'élaboration des discours, nous avons analysé le Type-Token Ratio (TTR), une mesure fréquemment utilisée en *Text Mining*, comparant le nombre de tokens distincts au nombre total de tokens. L'analyse de sa distribution (Annexe 7) montre que la majorité des critiques sont concentrées autour de valeurs élevées, comprises entre 0.75 et 0.90. Cela témoigne d'une diversité lexicale importante, caractéristique d'une argumentation personnalisée.

La mise en relation du TTR avec la note attribuée aux films (Annexe 8) révèle une légère décroissance. Les reviews présentant des notes plus faibles (notes de 0.5 à 1.5) affichent un

TTR d'environ 0.85, tandis que ce ratio tend à diminuer progressivement jusqu'à 0.80 pour les critiques les mieux notées (notes de 3.5 à 4). Bien que marginale, cette différence suggère que les avis défavorables mobilisent un vocabulaire légèrement plus diversifié, possiblement dû à un effort argumentatif plus important, alors que les critiques positives reposent davantage sur des formulations récurrentes.

Ces résultats doivent toutefois être interprétés avec prudence. La distribution des notes (Annexe 1) révèle que la majorité des critiques affiche des scores moyens et élevés, ce qui peut introduire un biais statistique relatif au faible nombre d'observations avec des notes faibles. De plus, l'analyse des boxplots (Annexe 2), mettant en relation la note et la longueur des discours, révèle que les notes favorables sont généralement attribuées à des reviews plus longues. Sachant que le TTR est fortement influencé par la longueur des textes, les évaluations plus longues pourraient expliquer la baisse du TTR lorsque les notes s'avèrent plus élevées.

Analyse sémantique

A la suite de l'analyse descriptive, cette section vise à effectuer une lecture sémantique des œuvres en s'appuyant sur un thésaurus de polarité lexicale (basé sur VADER). Ce dernier permet de déterminer quelles sont les unités lexicales porteuses d'un « poids » évaluatif et de leur associer une orientation positive ou négative. Les analyses qui suivent cherchent donc à examiner les relations entre polarité lexicale, intensité du sentiment et note attribuée aux reviews.

Vocabulaire évaluatif : mots porteurs de jugement

L'analyse des mots évaluatifs les plus fréquents (Annexe 9) illustre un lexique principalement positif, dominé par des mots comme *love*, *well*, *best*, *kind* et *great*. Leur forte présence souligne le rôle central que joue le vocabulaire appréciatif au sein des jugements formulés. D'autres mots à connotation négative sont également présents mais sont en grande partie spécifiques au domaine cinématographique. En effet, des termes comme *death*, *horror* ou encore *fight* ne participent pas à la formulation d'une évaluation défavorable mais plutôt à la description d'éléments narratifs ou génériques.

Etude des relations : polarité globale, ratio positif/négatif et score

Dans l'étude de la relation entre le contenu évaluatif des critiques et les notes attribuées, deux indicateurs complémentaires ont été pris en compte : le compound sentiment score et le pos/neg ratio. L'avantage que présente le compound score est qu'il permet de mesurer de manière globale la polarité d'un discours et ce, en tenant compte de l'intensité des mots, de leur contexte et des effets liés à la négation. Une fois cette mesure mise en relation avec le score, comme le montre le graphique « *Review score vs Compound Sentiment* » (Annexe 10), nous observons une corrélation positive : les films notés plus favorablement font appel à un lexique à tonalité positive plus prononcée. Toutefois, il est important de noter que pour un même score le

compound score peut varier de valeurs fortement positives à négatives. Bien que le compound score tend à croître avec le score, il n’y a pas de correspondance entre note attribuée et tonalité émotionnelle. Cette constatation souligne ce qui a été avancé dans l’analyse descriptive : les reviews étudiées correspondent davantage à des critiques argumentées plutôt qu’à de simples réactions émotionnelles.

Le ratio mots positifs/mots négatifs correspond, quant à lui, à une mesure plus structurelle basée sur le comptage du nombre de mots positifs et négatifs. Comme illustre le graphique « *Positive/Negative Word Ratio vs Review Score* » (Annexe 11), ce ratio a tendance, lui-aussi, à augmenter avec la note attribuée. Un point à noter est que, comparativement à ce qui a été observé avec le compound score, la relation apparaît ici moins régulière. Certaines critiques disposant d’une note intermédiaire (2.5) présentent des ratios bien plus importants, là où des critiques particulièrement bien notées peuvent afficher un ratio plus modéré. A nouveau, nous saisissons ici la complexité du discours critique : un avis favorable peut contenir de nombreuses réserves, et une évaluation négative peut tout à fait mettre en avant certaines qualités d’une œuvre.

Structure narrative : trajectoire de sentiment

Pour une compréhension plus complète de la dynamique émotionnelle des critiques, une analyse complémentaire particulièrement éclairante sur la manière dont le sentiment évolue au fil de la structure narrative est présentée en annexe 12. Nous vous invitons donc vivement à la consulter.

Groupement des documents

À la suite de l’analyse sémantique, l’objectif a été d’identifier des structures latentes au sein du corpus. Plutôt que de s’appuyer sur des étiquettes préexistantes (comme les genres cinématographiques déclarés), une approche de clustering a été privilégiée. Cette méthode exploratoire permet aux données de s’organiser d’elles-mêmes selon leurs similarités statistiques intrinsèques, révélant ainsi des thématiques ou des tonalités critiques que les classifications standards ne capturent pas nécessairement. L’algorithme K-Means a été retenu pour son efficacité sur des données de haute dimension. Appliqué après la réduction dimensionnelle (SVD) et la normalisation, il partitionne le corpus en K groupes en minimisant la variance intra-classe et en maximisant la variance inter-classe, rassemblant ainsi les critiques sémantiquement proches autour de centroïdes moyens.

Détermination du nombre de clusters K

Le nombre de clusters a été déterminé en évaluant plusieurs valeurs de K comprises entre 2 et 12 à l’aide d’une implémentation automatisée de K-Means. Chaque configuration a été évaluée à l’aide du score de Silhouette (distance cosinus), mesurant le compromis entre cohésion intra-classe et séparation inter-classe. La valeur $K = 12$ a obtenu le score maximal (0.032) parmi les configurations testées et a été retenue comme nombre optimal de clusters, un résultat cohérent avec la nature des données textuelles aux frontières thématiques diffuses (Annexe 13).

Analyse croisée

TABLE 2 – Synthèse des clusters thématiques

Cluster	Thématique	Mots-clés dominants	Nbr Docs	Note moy.	Sentiment moy.
2	Horreur	<i>horror, house, haunt, scare, night</i>	56	2.64	-0.353
4	Musical	<i>song, music, band, musical, singer</i>	43	3.29	0.890
8	Guerre	<i>war, soldier, military, bomb, fight</i>	36	3.40	-0.247
11	Société / Racisme	<i>black, white, racist, racism, nation</i>	16	3.28	0.272

L’observation des clusters révèle une segmentation thématique fine opérée sans supervision. Le Cluster 4 (Musical) se détache par le sentiment moyen le plus élevé (0.890), porté par un vocabulaire intrinsèquement positif (*song, love*). À l’opposé, c’est le Cluster 9 (Crime) qui enregistre le sentiment le plus négatif du corpus (-0.454), suivi de près par le Cluster 2 (Horreur, -0.353), reflétant la noirceur sémantique de leurs champs lexicaux respectifs (*murder, killer* et *horror, scare*). Un phénomène particulièrement notable apparaît avec le Cluster 8 (Guerre). Ce groupe affiche la note moyenne la plus élevée (3.40/4), signe d’une forte appréciation critique, tout en présentant un sentiment composé négatif (-0.247). Ce paradoxe apparent valide la pertinence de l’approche : l’algorithme de sentiment (VADER) capte correctement la négativité du vocabulaire martial (*war, bomb, fight*), mais cette tonalité sombre n’est pas corrélée à la qualité artistique perçue de l’œuvre. Par ailleurs, le Cluster 11, bien que minoritaire (16 documents), isole avec précision les films traitant de questions raciales (*racist, racism*).

Link analysis

Après avoir exploré le contenu textuel des critiques cinématographiques de manière isolée (*Text mining*) cette dernière phase du projet vise à modéliser le corpus sous la forme d’un graphe. L’objectif est de dépasser l’analyse fréquentielle des mots afin de révéler la structure relationnelle qui unit l’ensemble des oeuvres. Pour ce faire, l’ensemble des critiques a été converti en un graphe non orienté où les noeuds représentent les critiques, tandis que les arêtes matérialisent leur similarité sémantique (cosinus).




FIGURE 1 – Visualisation du réseau (Gephi) coloré par Clusters.

Méthodologie

Dans la quête de pertinence sémantique un nouveau filtre plus strict, a été appliqué dans la phase de prétraitement. En effet, lors du *Text mining*, les 12 clusters se sont avérés cohérents mais aussi quelque peu pollués par des termes génériques et cinématographiques. Une liste a donc été créée afin de supprimer ces mots "parasites". Cette étape vise à éviter que deux critiques soient liées artificiellement par des tics de langage propres au monde du cinéma. Fidèle au pipeline de *Text mining*, la vectorisation (TF-IDF) et la réduction SVD (150 composantes) ont permis d'extraire 12 thèmes latents du corpus. Cette continuité méthodologique garantit une parfaite cohérence sémantique entre l'analyse textuelle et la construction du réseau.

La génération des arêtes du graphe ne repose pas ici sur un seuil de similarité unique, mais plutôt sur une stratégie qui privilégie la formation des clusters :

- **Densité locale (intra-cluster)** : Chaque oeuvre se connecte à ses 4 plus proches voisins sémantiques qui appartiennent au même thème (seuil de similarité > 0.30).
- **Ponts sémantiques (inter-cluster)** : Pour révéler les connexions transversales, chaque critique peut créer un lien vers un thème différent, uniquement avec un seuil de similarité stricte (> 0.50).

Cette double stratégie de filtrage vise à favoriser la cohésion interne des clusters via un seuil de tolérance (0.30), tout en restreignant les ponts inter-thématiques à des similarités fortes (0.50) pour garantir une structure modulaire robuste et navigable.

Analyse du réseau

TABLE 3 – Statistiques Globales du Réseau (12 Clusters)

Métrique	Valeur
Nombre de Nœuds ($ V $)	892
Diamètre (Max Eccentricity)	15
Distance Moyenne (Shortest Path)	6.90
Rayon (Min Eccentricity)	1
Partition Spectrale (Groupe A / B)	463 / 429

L'analyse des propriétés globales du graphe permet de qualifier la structure de l'univers critique collecté. Les statistiques (Table 3) décrivent un réseau de type "*Small World*". Pour comprendre la topologie, nous avons analysé l'excentricité, qui mesure pour chaque nœud la distance maximale le séparant de tout autre nœud du graphe. Le diamètre de 15 sauts (l'excentricité maximale) et la distance moyenne de 6.90 indiquent un réseau vaste mais navigable : il est possible de relier sémantiquement deux films quelconques en moins de 7 étapes en moyenne. Cependant, le rayon de 1 (l'excentricité minimale) révèle une anomalie structurelle : la présence d'îlots sémantiques déconnectés. Certains nœuds ont une excentricité très faible car ils appartiennent à de petites composantes isolées (documentaires spécifiques ou films d'horreur codifiés) qui ne sont pas reliées au graphe géant principal. Cette fragmentation reflète la diversité du corpus : tous les films ne se

fondent pas dans le courant « mainstream ».

De plus, la partition spectrale (basée sur le vecteur de Fiedler) divise le graphe en deux communautés équilibrées (463 vs 429 critiques). Contrairement au clustering K-Means qui regroupe les films selon leurs mots-clés, elle cherche la coupure la plus propre pour diviser le graphe en deux. Dans notre cas, celle-ci n'est pas thématique : les genres majeurs (love/friend, guy/money, family/father) dominent dans les deux groupes. Cela suggère que le réseau n'est pas polarisé par les sujets mais qu'il est très probablement structuré par d'autres facteurs stylistiques.

Mesures de centralité, de prestige et d'influence

Plusieurs métriques de centralité et de prestige ont été confrontées (Annexes 14 et 15). Ci-dessous, voici les analyses relatives à celles-ci.

PageRank et Degree : L'algorithme du PageRank a été appliqué au graphe non orienté. Bien qu'initialement conçu pour les graphes orientés, son usage est pertinent pour mesurer l'importance des critiques dans le réseau : une oeuvre est influente si elle est similaire à d'autres critiques influentes, à l'image des pages web référencées. Nous observons une corrélation très forte ($r_s = 0.93$) entre le Degree (nombre de liens) et le PageRank. Cette convergence entre les deux métriques désigne les leaders du réseau : *Star Wars (Episode IV)* émerge ici comme le noeud central. Il est considéré comme le noyau du cluster "Science-Fiction", servant de référence lexicale pour tout le genre.

Analyse des ponts et flux d'information : Nous avons calculé la Betweenness Centrality pour identifier les goulots d'étranglement. Contrairement aux noyaux populaires, ce sont des films comme *Is This Thing On ?* qui apparaissent en tête : ils agissent comme des ponts uniques connectant des communautés disjointes via le plus court chemin. Cependant, nous avons jugé cette mesure trop restrictive car elle se limite au chemin le plus court. Pour capter la richesse sémantique, nous avons introduit l'Information Centrality (via la pseudo-inverse de la matrice Laplacienne L^+), qui modélise la diffusion sur l'ensemble des chemins possibles. Les résultats (Annexe 15) révèlent des scores parfaits (1.0) pour les neuf premiers films comme *Misery*. La corrélation négative avec le Degree (-0.17) confirme que ces œuvres ne sont pas des blockbusters au vocabulaire généraliste, mais des piliers indispensables au sein de groupes spécifiques, assurant une cohésion interne maximale. L'Information Centrality privilégie ici la robustesse du réseau (multitude de chemins) plutôt que la simple efficacité du plus court chemin.

Le biais de la Closeness Centrality : Cette mesure met en évidence les effets d'îlots. Des scores parfaits de 1.0 en Closeness pour des films tels que *La Femme Nikita* confirment l'analyse précédemment réalisée : ces critiques sont des centres absolus de petites communautés isolées. Dans le graphe principal, *Star Wars* (Closeness 0.17) doit quant à lui, malgré sa centralité, traverser beaucoup d'intermédiaires pour atteindre la périphérie.

Topologie inter-cluster

Au-delà de toute métrique individuelle, nous avons également cherché à comprendre comment les 12 thèmes s’organisent réellement les uns par rapport aux autres, au travers de la distance topologique moyenne (via l’algorithme Floyd-Warshall) entre les critiques de chaque cluster. L’analyse de la matrice des distances moyennes (Annexe 16) révèle une topologie polarisée. On observe une proximité structurelle modérée entre des clusters tels que ceux liés au crime, à l’action et à la famille indiquant un vocabulaire partagé. À l’opposé, le cluster « Musical » apparaît comme une singularité sémantique, relativement distant de la majorité des clusters de thèmes identifiés. Cette cartographie valide l’approche par graphe : elle ne se contente pas de classer les films, elle dessine la « carte mentale » de l’ensemble des critiques collectées.

Conclusion

Ce projet a permis d’explorer de façon approfondie la manière dont les critiques publiées sur le blog *RogerEbert.com* expriment l’appréciation des œuvres et s’articulent au sein d’un univers structuré. La problématique initialement posée consistait à examiner l’alignement entre le contenu des critiques et les notes attribuées, tout en identifiant les relations thématiques émergentes entre les reviews analysées.


La collecte de données a consisté en l’élaboration d’un processus de scraping automatisé, reposant sur une combinaison entre exploration BFS et filtrage ciblé des URL pertinentes. Ce choix a permis de limiter le bruit et de garantir une couverture convenable, garantissant ainsi l’obtention d’un corpus cohérent de 900 critiques. La phase de *Text Mining* a ensuite permis de transformer ce corpus en un ensemble de données interprétables. Par le biais des phases successives que sont le nettoyage, la tokenisation, la lemmatisation et le filtrage, le vocabulaire a été condensé en 34 000 termes uniques.

L’analyse descriptive et sémantique a révélé un corpus riche lexicalement, composé de nombreux termes évaluatifs. A ces constatations s’ajoute également le fait que les avis formulés sont particulièrement nuancés et ne correspondent pas à des verdicts tranchés. Bien qu’une corrélation globale existe entre polarité lexicale, ratio positif/négatif et notes attribuées, les critiques expriment fréquemment des réserves et des variations de sentiment au fil du discours. Les critiques ne se résument donc pas à une simple émotion positive ou négative.

L’application de l’algorithme du K-Means a mis en évidence l’existence de divers regroupements thématiques, tout en révélant des paradoxes comme des films aux tonalités lexicales négatives mais à l’appréciation élevée, soulignant la diversité et la complexité des discours critiques. Enfin, la *Link Analysis* offre une vision relationnelle du corpus. Le graphe fondé sur les similarités sémantiques a permis l’identification de plusieurs nœuds essentiels et de la structure du réseau. L’analyse des centralités et des distances entre clusters révèle que certaines œuvres jouent un rôle pivot, tandis que d’autres servent de passerelles reliant des ensembles critiques plus éloignés.


Annexes

Annexe 1



Annexe 1: Distribution des scores des critiques

Annexe 2




Annexe 2: Distribution de la longueur des critiques en fonction du score

Annexe 3

Review 1	Score 1	Review 2	Score 2	Cosine similarity
A Bug's Life (1998)	3.5	Aritz (1998)	3.5	0.945
Dog Day Afternoon (1975)	3.5	Long day's journey into night (1975)	4.0	0.901
Beast of War (2025)	3.0	Jaws (1975)	4.0	0.88
Aliens (1986)	3.5	Throw another prawn on the barbie (2009)	3.0	0.878
Dog Day Afternoon (1975)	3.5	Heist School Confidential (2006)	2.5	0.86
Queen of the Damned (2002)	2.0	Nosferatu (1922)	4.0	0.858
Heist School Confidential (2006)	2.5	Long day's journey into night (1975)	4.0	0.848
Aliens (1986)	3.5	Alien (1979)	4.0	0.838
Alien (1979)	4.0	Throw another prawn on the barbie (2009)	3.0	0.837
Triforce (2025)	3.0	The Tuffie Hunters (2021)	3.0	0.834
Alien (1979)	4.0	Galaxy Quest (1999)	3.0	0.799
Kill Bill, Volume 1 (2003)	4.0	Kill Bill, Volume 2 (2004)	4.0	0.788
House of Games (1987)	4.0	The Spanish Prisoner (1998)	3.5	0.781
Road Diary: Bruce Springsteen and The E Street Band (2024)	3.0	This is Spinal Tap (1985)	4.0	0.776
Detroit (2017)	2.0	School Daze (1988)	3.5	0.773
Five Nights at Freddy's 2 (2025)	3.0	Five Nights at Freddy's 2 (2023)	2.0	0.763
Galaxy Quest (1999)	3.0	Throw another prawn on the barbie (2009)	3.0	0.755
Aliens (1986)	3.5	Galaxy Quest (1999)	3.0	0.755
Bull Durham (1988)	3.5	Who Killed the Montreal Expos? (2025)	3.5	0.754
Union (2024)	3.0	Bread And Roses (2001)	3.5	0.751
Bamboozled (2000)	2.0	School Daze (1988)	3.5	0.75
Detroit (2017)	2.0	Cry Freedom (1987)	2.5	0.748
Queens of the Dead (2025)	3.0	World War Z (2013)	2.0	0.748
Who Killed the Montreal Expos? (2025)	3.5	Clemente (2025)	2.0	0.746
Out of Sight (1998)	3.5	Long day's journey into night (1975)	4.0	0.743
School Daze (1988)	3.5	Cry Freedom (1987)	2.5	0.743
Tiger Zinda Hai (2017)	3.0	Fighter (2024)	3.0	0.741
Dawn of the Dead (1979)	4.0	World War Z (2013)	2.0	0.738
The Rider (2018)	4.0	East of Wall (2025)	3.5	0.737
Out of Sight (1998)	3.5	Heist School Confidential (2006)	2.5	0.733
A New Testament story in an Old Testament land (1988)	4.0	The Irishman (2019)	3.5	0.733
Almost Famous (2000)	4.0	This is Spinal Tap (1985)	4.0	0.732
Train to Busan (2016)	3.0	World War Z (2013)	2.0	0.722
Logan (2017)	3.5	We believed a man could fly (1978)	4.0	0.717
Out of Sight (1998)	3.5	Dog Day Afternoon (1975)	3.5	0.714
Nine Queens (2002)	3.0	House of Games (1987)	4.0	0.712
The Birth of a Nation (1915)	4.0	Bamboozled (2000)	2.0	0.71
Fall of the sparrow (2007)	4.0	Nashville (1975)	4.0	0.709
Killers of the Flower Moon (2023)	4.0	The Irishman (2019)	3.5	0.707
Zodiac Killer Project (2025)	3.0	Strange Harvest (2025)	2.5	0.705
Sharper (2023)	2.0	House of Games (1987)	4.0	0.705
RRR (2022)	3.5	Fighter (2024)	3.0	0.702


Annexe 3: Exemples de paires de critiques présentant une forte similarité cosinus

Annexe 4




Annexe 4: Barplot top 20 des mots les plus fréquents

Annexe 5




Annexe 5: Nuage de mots top 20 des mots les plus fréquents

Annexe 6




Annexe 6: Barplot top 10 2-grams

Annexe 7




Annexe 7: Histogramme du Type-Token Ratio (TTR)

Annexe 8




Annexe 8: Analyse de la relation entre TTR et scores attribués aux critiques

Annexe 9




Annexe 9: Barplot top 20 mots évaluatifs

Annexe 10



Annexe 10: Analyse de la relation entre Compound sentiment score et scores attribués aux critiques


Annexe 11



Annexe 11: Analyse de la relation entre ratio mots positifs/négatifs et scores attribués aux critiques

Annexe 12

A la suite de l'analyse de la polarité globale, cette partie repose sur une approche dynamique en étudiant l'évolution du sentiment au sein des critiques. Chaque texte a été découpé selon une structure narrative classique (introduction, développement, milieu, climax, conclusion), puis évalué par segment sur base du compound score.



Annexe 12: Analyse de la trajectoire de sentiment entre les films "outstanding" et "disappointing"

Les trajectoires observées soulignent une différence notable entre les *outstanding films* (notes de 3-4) et les *disappointing films* (notes de 0-2). Dès l'introduction, les films bien notés présentent une polarité positive (compound score moyen = 0.3), tandis que les films décevants adoptent un style plus neutre (compound score moyen = 0.1). Durant le développement initial, les reviews bien notées connaissent une légère baisse du sentiment (compound score moyen = 0.22) avant une stabilisation, suggérant l'expression de certaines réserves, alors que les *disappointing films* subissent une chute plus prononcée (compound score moyen = 0), informant de la présence d'arguments négatifs plus prononcés. La phase du climax constitue un point de bascule pour les deux catégories. Les *outstandings films* enregistrent une hausse importante de la polarité (compound score moyen = 0.35), soulignant un renforcement du jugement positif. Les critiques mal notées connaissent également une remontée (compound score moyen = 0.2), appuyant l'existence d'éléments appréciatifs même dans les évaluations négatives. Enfin, la conclusion semble être la section la plus discriminante : les critiques à la note favorable se terminent sur un sentiment assez positif (compound score moyen = 0.55), là où les *disappointing films* présentent une polarité plus modérée (compound score moyen = 0.15).

Annexe 13

Cluster	Thématique identifiée	Mots-clés dominants	Nbr Docs	Note moy.	Sentiment moy.
0	Sci-Fi / Action	<i>action, alien, effect, hero, computer</i>	115	3.06	0.523
1	Aventure / Animaux	<i>dog, town, train, school, animal</i>	36	3.06	0.463
2	Horreur	<i>horror, house, haunt, scare, night</i>	56	2.64	-0.353
3	Drame Familial	<i>family, love, comedy, relationship</i>	120	3.15	0.715
4	Musical	<i>song, music, band, musical, singer</i>	43	3.29	0.890
5	Documentaire	<i>documentary, news, interview, bank</i>	109	3.00	0.487
6	Teen Movie / École	<i>school, kid, comedy, high school</i>	104	3.17	0.395
7	Vocabulaire Critique	<i>world, something, best, really, truly</i>	80	2.92	0.521
8	Guerre	<i>war, soldier, military, bomb, fight</i>	36	3.40	-0.247
9	Crime / Thriller	<i>crime, murder, killer, police, case</i>	42	2.85	-0.454
10	Drame (Femmes)	<i>woman, world, moment, love, girl</i>	143	3.25	0.342
11	Société / Racisme	<i>black, white, racist, racism, nation</i>	16	3.28	0.272

Annexe 13: Synthèse des clusters thématiques

Annexe 14

Degree Centrality (Hubs)		PageRank (Influence)	
Film	Score	Film	Score
Star Wars (Ep. IV)	18	Star Wars (Ep. IV)	0.0035
Anniversary	16	Anniversary	0.0034
Merrily We Roll Along	15	The Green Berets	0.0029
The Green Berets	14	Is This Thing On ?	0.0027
Licorice Pizza	14	Licorice Pizza	0.0027


Annexe 14: Top 5 Films par Degree et Page Rank

Annexe 15

Betweenness Centrality		Information Centrality	
Film	Score	Film	Score
Is This Thing On ?	0.069	Misery	1.0
Materialists	0.068	She Walks in Darkness	1.0
The Farewell	0.064	The Stringer	1.0
Bone Lake	0.061	A magnificent puzzlement	1.0
The Mastermind	0.058	Judge Dredd	1.0

Annexe 15: Top 5 Films par Betweenness et Information Centrality

Annexe 16



Annexe 16: Matrice des distances moyennes (sauts) entre les clusters thématiques.