

WEB MINING

Analyse de critiques cinématographiques

SCRAPING

Constituer un corpus représentatif

- **Mise en place d'une stratégie Breadth-First Search :**
 - Critiques de départ → analyser leur contenu → ajout à la file d'attente
- **Imposition d'une contrainte de profondeur (<2)**
 - Rester focalisé sur les citations directes
 - Garder une structure logique dans les relations
- **Après nettoyage et parsing (BS)**
 - Aboutissement à un corpus structuré de 900 critiques

TRAITEMENT DE TEXTE

Matière brute → Exploitable

- **Nettoyage syntaxique :**
 - Ponctuation, harmonisation de la casse
- **Lemmatisation conditionnelle :**
 - Couper les mots bêtement → Utilisation POS tagging
- **Filtrage sémantique et statistique massif**
 - Retirer les stopwords et noms propres
 - Seuils de fréquence : mots rares/fréquents

Résultat

- Réduction de bruit de 63%
- → Dictionnaire de 34 000 termes

- **Objectif → Interprétation**
 - TF-IDF
 - BERT et Word2Vec ?
- **Gestion de la haute dimensionnalité :**
 - SVD
 - Condenser le bruit (150)
 - Densifiant l'information
- **Mesure de similarité Cosinus**
 - Capturer les thématiques communes

<i>A Bug's Life</i>	Antz	94%
---------------------	------	------------

ANALYSE DESCRIPTIVE

Unigrams

- **Plus qu'une simple citation**
- **Tokens les plus fréquents** : *woman, world, love, best* → interprétation et évaluation

Bigrams

- **Bigrams les plus fréquents** : *special effect, best friend* → aspects techniques et relations entre personnages
- **Expressions** : *high school, comic book* → articulation du corpus autour d'univers culturels

Type-Token Ratio

- **Richesse lexicale importante**

ANALYSE SÉMANTIQUE

Fréquence des mots évaluatifs



- **Mots positifs dominant** : *love, well, best*
- **Mots négatifs** : reflètent le contexte du film

Relation entre sentiment et score

- **Films mieux notés** : vocabulaire plus positif
- **Variations importantes pour un même score**
- **Complexité des évaluations**

Trajectoires de sentiment

- **Films bien notés (3-4)** : introduction ↗, développement ↘, conclusion ↗
- **Films mal notés (0-2)** : neutres, légèrement négatifs et passages positifs



ANALYSE THÉMATIQUE

Clustering

- **Regroupement** : similitude sémantique
- **K-Means** : 12 clusters aux thématiques latentes

Analyse des clusters

- **Cluster “Musical”** : sentiment très positif
- **Cluster “Horreur”** : vocabulaire sombre et négatif
- **Cluster “Guerre”** : lexique négatif et notes élevées
- **Tonalité lexicale $\perp$ appréciation artistique**

Cluster	Thématique identifiée	Mots-clés dominants	Nbr Docs	Note moy.	Sentiment moy.
0	Sci-Fi / Action	<i>action, alien, effect, hero, computer</i>	115	3.06	0.523
1	Aventure / Animaux	<i>dog, town, train, school, animal</i>	36	3.06	0.463
2	Horreur	<i>horror, house, haunt, scare, night</i>	56	2.64	-0.353
3	Drame Familial	<i>family, love, comedy, relationship</i>	120	3.15	0.715
4	Musical	<i>song, music, band, musical, singer</i>	43	3.29	0.890
5	Documentaire	<i>documentary, news, interview, bank</i>	109	3.00	0.487
6	Teen Movie / École	<i>school, kid, comedy, high school</i>	104	3.17	0.395
7	Vocabulaire Critique	<i>world, something, best, really, truly</i>	80	2.92	0.521
8	Guerre	<i>war, soldier, military, bomb, fight</i>	36	3.40	-0.247
9	Crime / Thriller	<i>crime, murder, killer, police, case</i>	42	2.85	-0.454
10	Drame (Femmes)	<i>woman, world, moment, love, girl</i>	143	3.25	0.342
11	Société / Racisme	<i>black, white, racist, racism, nation</i>	16	3.28	0.272

QUELQUES SUBTILITÉS

Cohérence et robustesse

- Mêmes procédures que le Text Mining
- Filtre lexical (mots génériques et jargon cinéma)

Densité locale


- Seuil > 0.3
- Solidification des clusters

Ponts sémantiques

- Seuil de similarité > 0.5
- Structure robuste et navigable



GRAPHE GEPHI : SMALL WORLD



Caractéristiques générales

- **Distance moyenne** : 6.90 sauts
- **Diamètre** : 15
- **Rayon** : 1

Ilots sémantiques

- **Films niches ou documentaires** : “La femme Nikita”

QUI SONT LES ACTEURS MAJEURS ?

Degree et PageRank

- **Star Wars (Episode IV)** : noyau de la Science-Fiction

Betweenness Centrality


- **“Is this thing on?”** : goulot d'étranglement
- **Pont entre communautés**

Information Centrality

- **“Misery”** : point de passage de l'information



DISTANCES INTER CLUSTER





MERCI POUR VOTRE ATTENTION



BACK UP SLIDES

Annexe 1







Annexe 3


Review 1	Score 1	Review 2	Score 2	Cosine similarity
A Bug's Life (1998)	3.5	Antz (1998)	3.5	0.945
Dog Day Afternoon (1975)	3.5	Long day's journey into night (1975)	4.0	0.901
Beast of War (2025)	3.0	Jaws (1975)	4.0	0.88
Aliens (1986)	3.5	Throw another prawn on the barbie (2009)	3.0	0.878
Dog Day Afternoon (1975)	3.5	Heist School Confidential (2006)	2.5	0.86
Queen of the Damned (2002)	2.0	Nosferatu (1922)	4.0	0.858
Heist School Confidential (2006)	2.5	Long day's journey into night (1975)	4.0	0.848
Aliens (1986)	3.5	Alien (1979)	4.0	0.838
Alien (1979)	4.0	Throw another prawn on the barbie (2009)	3.0	0.837
Trifole (2025)	3.0	The Truffle Hunters (2021)	3.0	0.834
Alien (1979)	4.0	Galaxy Quest (1999)	3.0	0.799
Kill Bill, Volume 1 (2003)	4.0	Kill Bill, Volume 2 (2004)	4.0	0.788
House of Games (1987)	4.0	The Spanish Prisoner (1998)	3.5	0.781
Road Diary: Bruce Springsteen and The E Street Band (2024)	3.0	This is Spinal Tap (1985)	4.0	0.776
Detroit (2017)	2.0	School Daze (1988)	3.5	0.773
Five Nights at Freddy's 2 (2025)	3.0	Five Nights at Freddy's (2023)	2.0	0.763
Galaxy Quest (1999)	3.0	Throw another prawn on the barbie (2009)	3.0	0.755
Aliens (1986)	3.5	Galaxy Quest (1999)	3.0	0.755
Bull Durham (1988)	3.5	Who Killed the Montreal Expos? (2025)	3.5	0.754
Union (2024)	3.0	Bread And Roses (2001)	3.5	0.751
Bamboozled (2000)	2.0	School Daze (1988)	3.5	0.75
Detroit (2017)	2.0	Cry Freedom (1987)	2.5	0.748
Queens of the Dead (2025)	3.0	World War Z (2013)	2.0	0.748
Who Killed the Montreal Expos? (2025)	3.5	Clemente (2025)	2.0	0.746
Out of Sight (1998)	3.5	Long day's journey into night (1975)	4.0	0.743
School Daze (1988)	3.5	Cry Freedom (1987)	2.5	0.743
Tiger Zinda Hai (2017)	3.0	Fighter (2024)	3.0	0.741
Dawn of the Dead (1979)	4.0	World War Z (2013)	2.0	0.738
The Rider (2018)	4.0	East of Wall (2025)	3.5	0.737
Out of Sight (1998)	3.5	Heist School Confidential (2006)	2.5	0.733
A New Testament story in an Old Testament land (1988)	4.0	The Irishman (2019)	3.5	0.733
Almost Famous (2000)	4.0	This is Spinal Tap (1985)	4.0	0.732
Train to Busan (2016)	3.0	World War Z (2013)	2.0	0.722
Logan (2017)	3.5	We believed a man could fly (1978)	4.0	0.717
Out of Sight (1998)	3.5	Dog Day Afternoon (1975)	3.5	0.714
Nine Queens (2002)	3.0	House of Games (1987)	4.0	0.712
The Birth of a Nation (1915)	4.0	Bamboozled (2000)	2.0	0.71
Fall of the sparrow (2007)	4.0	Nashville (1975)	4.0	0.709
Killers of the Flower Moon (2023)	4.0	The Irishman (2019)	3.5	0.707
Zodiac Killer Project (2025)	3.0	Strange Harvest (2025)	2.5	0.705
Sharper (2023)	2.0	House of Games (1987)	4.0	0.705
RRR (2022)	3.5	Fighter (2024)	3.0	0.702

Annexe 4







Annexe 6




Annexe 7




Annexe 8




Annexe 9




Annexe 10





Annexe 12




Annexe 13

Cluster	Thématique identifiée	Mots-clés domi- nants	Nbr Docs	Note moy.	Sentiment moy.
0	Sci-Fi / Action	action, alien, effect, hero, computer	115	3.06	0.523
1	Aventure / Animaux	dog, town, train, school, animal	36	3.06	0.463
2	Horreur	horror, house, haunt, scare, night	56	2.64	-0.353
3	Drame Familial	family, love, comedy, relationship	120	3.15	0.715
4	Musical	song, music, band, musical, singer	43	3.29	0.890
5	Documentaire	documentary, news, interview, bank	109	3.00	0.487
6	Teen Movie / École	school, kid, comedy, high school	104	3.17	0.395
7	Vocabulaire Critique	world, something, best, really, truly	80	2.92	0.521
8	Guerre	war, soldier, mili- tary, bomb, fight	36	3.40	-0.247
9	Crime / Thriller	crime, murder, killer, police, case	42	2.85	-0.454
10	Drame (Femmes)	woman, world, mo- ment, love, girl	143	3.25	0.342
11	Société / Racisme	black, white, racist, racism, nation	16	3.28	0.272

Degree Centrality (Hubs)		PageRank (Influence)	
Film	Score	Film	Score
Star Wars (Ep. IV)	18	Star Wars (Ep. IV)	0.0035
Anniversary	16	Anniversary	0.0034
Merrily We Roll Along	15	The Green Berets	0.0029
The Green Berets	14	Is This Thing On ?	0.0027
Licorice Pizza	14	Licorice Pizza	0.0027

Betweenness Centrality		Information Centrality	
Film	Score	Film	Score
Is This Thing On ?	0.069	Misery	1.0
Materialists	0.068	She Walks in Darkness	1.0
The Farewell	0.064	The Stringer	1.0
Bone Lake	0.061	A magnificent puzzlement	1.0
The Mastermind	0.058	Judge Dredd	1.0

Annexe 16



**THE
END**